Reto 2 — Visión por computador en COIL-100

Identificación de objeto, estimación de ángulo con incertidumbre y recuperación de vistas similares. Artefacto **vision-1.0.0** · receta **classic-logreg-v1** · hash de datos `e9e73124fbf0e964…` · SHA modelo `19cbc8a4516b0ecb…` · generado 2026-10-24.

1. Resumen ejecutivo

La solución productiva es una **receta clásica congelada**: histogramas HSV + HOG + LBP + momentos de Hu → estandarización → PCA(150) → **regresión logística C=1**; ángulo por recuperación condicionada al objeto con un score de incertidumbre en grados; y una regla ACT / REVIEW / REJECT cuyo objetivo es que el robot solo actúe cuando el riesgo medido en validación sea ≤ 2 % (con ≥ 50 casos de evidencia). La tolerancia de ±10° se traduce en **éxito extremo a extremo** (clase correcta y error circular ≤ 10°) y en el par de negocio **fracción automatizada** / **error entre ACT**. Todas las cifras siguientes son de esa receta, ajustada solo con el train de cada protocolo y evaluada **una vez** en su test.

Protocolo	Exactitud	MAE ángulo	≤10°	Éxito e2e	% ACT	n ACT	Error|ACT	IC95 Wilson
A · Interpolación	100.00%	2.71°	98.1%	98.1%	92.2%	3318	0.21%	[0.10, 0.43]%
B · Sector ciego 60°	97.00%	66.47°	28.6%	27.8%	0.0%	0	N/A	N/A
C · Escasez (12 vistas)	99.12%	13.13°	70.5%	69.8%	0.0%	0	N/A	N/A
D estricto · desconocidos	N/A	—	N/A	N/A	4.9%	35	100.00%	[90.11, 100.00]%
D variante · mixto	100.00%	3.07°	98.4%	98.4%	77.0%	3051	0.66%	[0.42, 1.01]%

Lectura: con referencias densas (A) la receta automatiza 92.2% con error entre ACT 0.21% (IC95 [0.10, 0.43]%). En B (arco ciego) y C (12 vistas) la validación no aporta evidencia suficiente y la receta desactiva la automatización: todo va a REVIEW. En D estricto se rechaza 77.5% de las vistas de objetos desconocidos y 4.86% llega a ACT (casi duplicados de un conocido); en la variante mixta, AUROC 0.993. El artefacto entregado es la misma receta ajustada con las 7.200 vistas: no tiene test propio y sus métricas esperadas son las de esta tabla.

2. Análisis del dataset

100 objetos × 72 vistas (paso exacto de 5°), 128×128 RGB, fondo oscuro casi uniforme (mediana del borde ≈ 25/255) e iluminación controlada. Propiedades que condicionan el diseño: (i) la clase es separable en laboratorio, el riesgo está en el ángulo; (ii) objetos **rotacionalmente simétricos** (latas, tazas, donas, frascos) cuyo ángulo es intrínsecamente ambiguo; (iii) en ~3/4 de los objetos la vista a 180° se parece más que la de 90°; (iv) familias de empaques casi duplicadas.

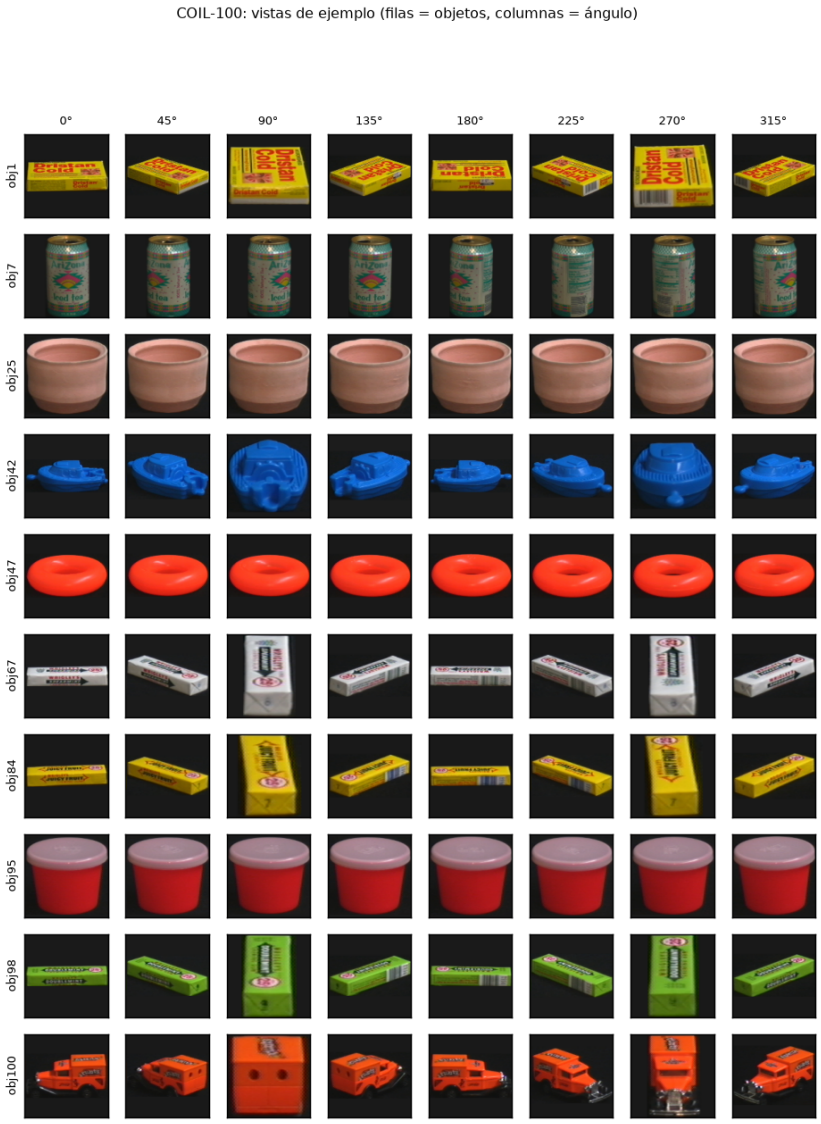


Figura 1. Vistas de ejemplo (filas: objetos; columnas: ángulo).

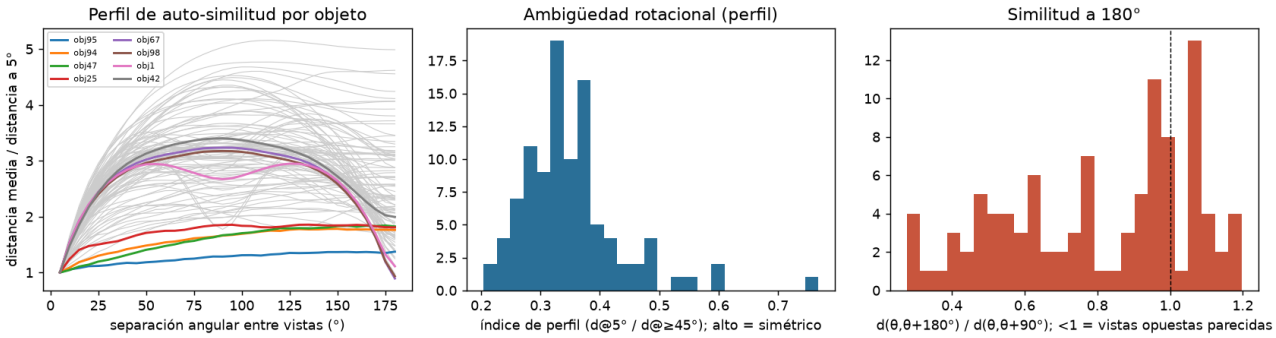


Figura 2. Izquierda: distancia media entre vistas vs. separación angular (plana = simétrico). Centro: índice de ambigüedad por objeto. Derecha: razón d(180°)/d(90°) (<1 = vistas opuestas parecidas).

Objetos más ambiguos según el índice de perfil: obj95 (0.77), obj94 (0.59), obj47 (0.59), obj25 (0.55), obj50 (0.53), obj34 (0.49), obj7 (0.48), obj86 (0.48). Tratamiento: bandera *rotational_ambiguity* por instancia (vista de referencia lejana casi tan parecida como la mejor), por clase con el índice LOO y con las clases cuyo ángulo falla en > 25 % de su validación (artefacto: obj47, obj67, obj84, obj94, obj95, obj98) → REVIEW.

Objeto A	Objeto B	Dist. mínima inter-objeto	Dist. típica vista adyacente
obj61	obj92	10.99	7.45
obj29	obj32	15.77	9.11
obj47	obj94	17.94	5.06
obj67	obj84	19.00	14.58

Objeto A	Objeto B	Dist. mínima inter-objeto	Dist. típica vista adyacente
obj15	obj91	19.25	13.88
obj1	obj15	19.81	13.35

Laboratorio vs. planta. En planta habrá cinta con textura y reflejos, iluminación variable, oclusión, desenfoque por movimiento, pose y escala de cámara variables y empaques nuevos. Mitigación: aumentación (brillo, contraste, blur, ruido, escala, recortes) y captura de referencias por estación; compuerta de calidad determinista previa al modelo; recalibración de umbrales con datos reales; piloto en sombra con revisión humana antes de habilitar ACT; monitoreo de deriva.

3. Metodología

Protocolo	Train / objeto	Test	Validación (solo dentro de train)
A Interpolación	0,10,…,350 (36)	5,15,…,355 (36)	fit paso 20°, val resto
B Sector ciego	60	arco contiguo 60° (12); inicio aleatorio, semilla 42	otro arco de 60° dentro de train
C Escasez	1 cada 30° (12)	las otras 60	fit paso 60°, val resto
D estricto	90 objetos, 72 vistas	solo las 720 vistas de 10 desconocidos	10 pseudo-desconocidos (semilla 43)
D variante	90 objetos, paso 10°	vistas impares de los 90 + 720 desconocidas	10 pseudo-desconocidos (semilla 43)

Desconocidos en D: obj9, obj10, obj20, obj42, obj61, obj69, obj72, obj83, obj95, obj97. Dos niveles: (1) **exploración** — cuatro clasificadores (kNN, logística, SVM RBF con Platt, Random Forest) con rejilla pequeña, comparados en validación; su test se reporta a título informativo y no se usa para elegir; (2) **receta congelada** — el ganador de la exploración más el procedimiento de umbrales, definido una vez y evaluado una vez por protocolo. El k de interpolación angular se elige en validación. Umbrales: máxima cobertura con error entre ACT ≤ 2 % y ≥ 50 ACT en validación; distancia de desconocido por Youden con pseudo-desconocidos; si no hay evidencia suficiente, automatización desactivada. Riesgos con IC de Wilson 95 %. Todo se registra en MLflow (sqlite:///mlflow.db, experimento vision-coil100): parámetros, métricas por protocolo, hash de datos, y para el artefacto model.joblib, su SHA-256, commit git y versiones de librerías.

4. Exploración: comparación de clasificadores

Exactitud de clase en **validación** (la única usada para elegir):

Clasificador / params	val A	val B	val C	val D
knn {"n_neighbors" 1}	97.72%	88.17%	78.17%	97.57%
knn {"n_neighbors" 5}	96.83%	84.33%	74.67%	96.88%
logreg {"C" 0.1}	99.33%	95.17%	87.83%	99.17%
logreg {"C" 1.0}	99.17%	95.42%	88.17%	99.17%
logreg {"C" 10.0}	99.17%	94.67%	88.00%	99.17%
svm_rbf {"C" 1.0}	97.61%	92.92%	76.50%	97.01%
svm_rbf {"C" 10.0}	99.28%	93.42%	78.50%	99.03%
random_forest {"n_estimators" 300}	96.89%	88.42%	80.50%	96.81%

La regresión logística tiene la mejor exactitud media de validación (≈3 puntos sobre SVM RBF y ≈5 sobre kNN y Random Forest) y es la mejor calibrada (ECE bajo), por lo que se congela como receta. Test de cada clasificador en la exploración (* = elegido en validación para ese protocolo; informativo):

Prot.	Clasificador	Exactitud	MAE°	Éxito e2e	ECE	fit (s)
A	knn	99.78%	2.66	97.9%	0.002	0.3
A	logreg *	99.97%	2.71	98.1%	0.014	0.5
A	svm_rbf	100.00%	2.71	98.1%	0.539	8.2
A	random_forest	99.86%	2.71	97.9%	0.355	7.8
B	knn	91.67%	64.31	16.4%	0.083	0.6
B	logreg *	97.00%	67.47	16.4%	0.018	1.1
B	svm_rbf	96.17%	66.26	16.4%	0.499	14.9
B	random_forest	93.00%	66.07	16.4%	0.464	12.9
C	knn	97.78%	9.03	88.1%	0.022	0.2
C	logreg *	99.12%	9.39	89.1%	0.018	0.3

Prot.	Clasificador	Exactitud	MAE°	Éxito e2e	ECE	fit (s)
C	svm_rbf	96.78%	9.22	87.2%	0.736	1.7
C	random_forest	96.85%	9.00	87.3%	0.515	2.4
D	knn	99.72%	2.58	98.2%	0.003	0.3
D	logreg *	100.00%	2.63	98.5%	0.001	0.3
D	svm_rbf	100.00%	2.63	98.5%	0.511	6.6
D	random_forest	99.72%	2.63	98.2%	0.352	5.8

5. Receta congelada: resultados, línea base y referencia moderna

Umbrales y k de la receta clásica en cada protocolo (todos elegidos en validación dentro del train del protocolo):

Protocolo	k (val)	Conf. mín.	Incert. máx.	Dist. desconocido	Val: n ACT	Val: error|ACT	Automatización
A · Interpolación	2	0.40	30.0°	36.29	1530	1.50%	sí
B · Sector ciego 60°	1	0.60	desactivada	38.78	0	N/A	no
C · Escasez (12 vistas)	1	0.70	desactivada	42.35	0	N/A	no
D estricto · desconocidos	1	0.95	30.0°	22.46	2696	0.30%	sí
D variante · mixto	3	0.90	12.5°	24.49	667	1.50%	sí

Comparación obligatoria con la misma contabilidad en todos los modelos: la línea base (1-NN en píxeles crudos 32×32) siempre actúa, por lo que en D sus aciertos sobre desconocidos son imposibles y cuentan como error entre ACT.

Prot.	Modelo	Exactitud	MAE ángulo	Éxito e2e	% ACT	Error|ACT	IC95
A	Receta clásica (prod.)	100.00%	2.71°	98.1%	92.2%	0.21%	[0.10, 0.43]%
A	Base píxeles 1-NN (siempre ACT)	99.97%	5.93°	97.6%	100.0%	2.42%	[1.96, 2.97]%
A	Receta con ResNet18	100.00%	1.98°	98.8%	0.0%	N/A	N/A
B	Receta clásica (prod.)	97.00%	66.47°	27.8%	0.0%	N/A	N/A
B	Base píxeles 1-NN (siempre ACT)	92.92%	61.22°	28.6%	100.0%	71.42%	[68.80, 73.90]%
B	Receta con ResNet18	99.67%	48.32°	27.9%	0.0%	N/A	N/A
C	Receta clásica (prod.)	99.12%	13.13°	69.8%	0.0%	N/A	N/A
C	Base píxeles 1-NN (siempre ACT)	97.38%	14.02°	74.3%	100.0%	25.72%	[24.63, 26.84]%
C	Receta con ResNet18	99.98%	11.35°	69.8%	0.0%	N/A	N/A
D estr.	Receta clásica (prod.)	N/A	—	N/A	4.9%	100.00%	[90.11, 100.00]%
D estr.	Base píxeles 1-NN (siempre ACT)	N/A	—	N/A	100.0%	100.00%	[99.47, 100.00]%
D estr.	Receta con ResNet18	N/A	—	N/A	2.2%	100.00%	[80.64, 100.00]%
D	Receta clásica (prod.)	100.00%	3.07°	98.4%	77.0%	0.66%	[0.42, 1.01]%
D	Base píxeles 1-NN (siempre ACT)	100.00%	5.94°	97.8%	100.0%	19.97%	[18.76, 21.25]%
D	Receta con ResNet18	100.00%	1.95°	99.0%	0.0%	N/A	N/A

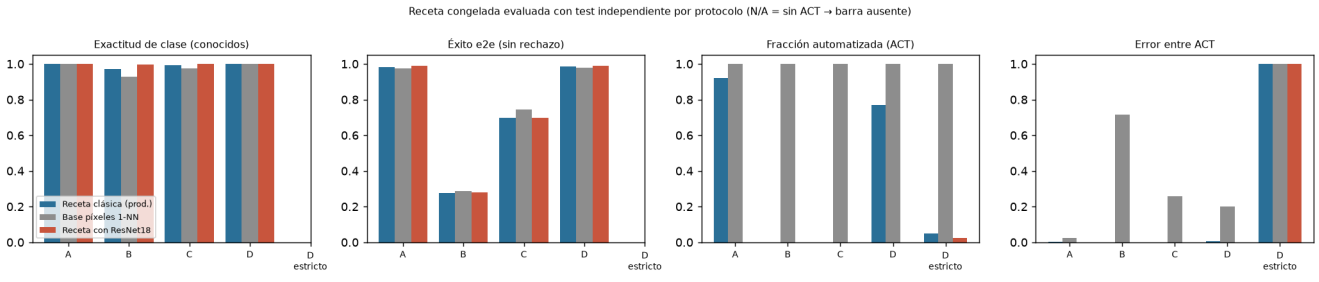


Figura 3. Receta congelada por protocolo (barra ausente = N/A, sin ACT).

6. Ángulo

Métrica: error circular min(|a−b|, 360−|a−b|), con MAE, mediana y fracción ≤ 10° sobre las predicciones con clase correcta. Alternativas: copiar el ángulo del vecino más cercano (k=1) o interpolar con 2–3 vecinos. Según la validación, interpolar ayuda cuando el query cae entre referencias cercanas (A, D) pero no con brechas grandes (B, C), donde k=1 queda igual o mejor; por eso k se elige por protocolo en validación.

Protocolo	k	val ≤10°	val MAE
A	1	80.7%	15.04
A	2	94.2%	8.59
A	3	94.1%	9.54
B	1	28.0%	61.58
B	2	16.8%	62.45
B	3	16.0%	63.25
C	1	0.0%	52.80
C	2	0.0%	52.80
C	3	0.0%	52.80
D_strict	1	98.3%	6.32
D_strict	2	98.3%	2.97
D_strict	3	98.2%	3.43
D	1	80.3%	15.92
D	2	93.6%	9.63
D	3	93.6%	10.56

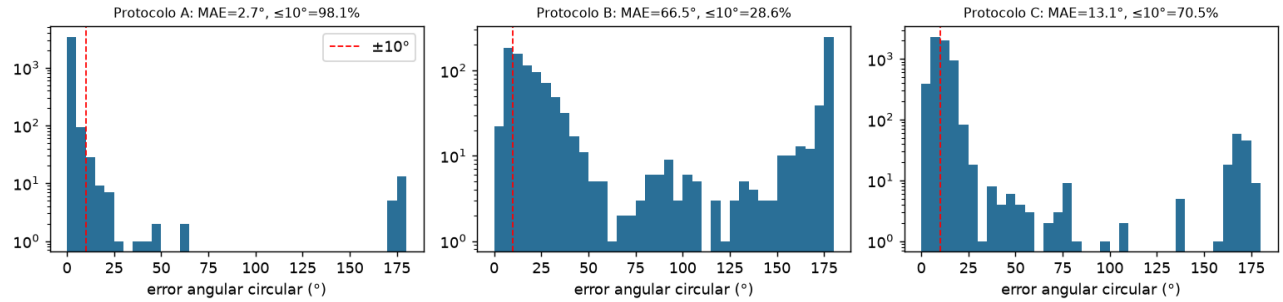


Figura 4. Histograma del error angular circular, receta clásica (escala log); rojo = ±10°.

7. Rechazo y calibración: ¿es la confianza una base válida para decidir?

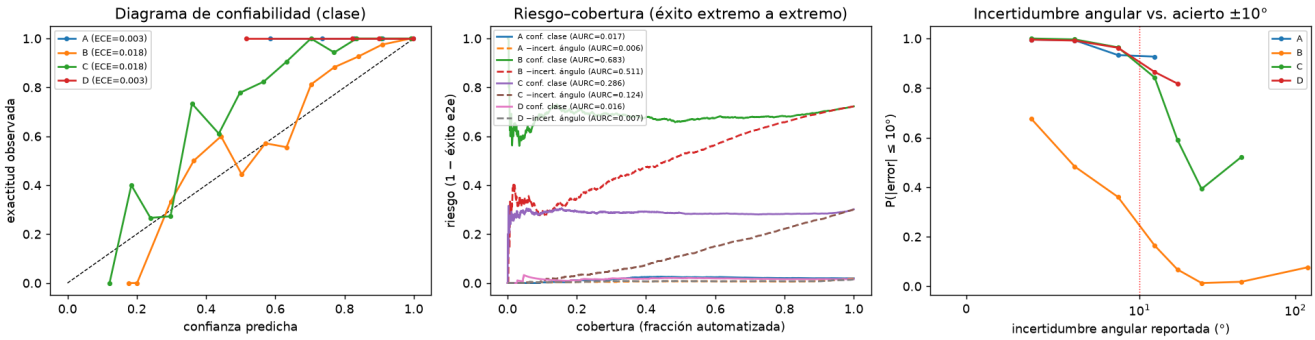


Figura 5. Confiabilidad (clase), riesgo–cobertura y P(|error| ≤ 10°) vs. score de incertidumbre.

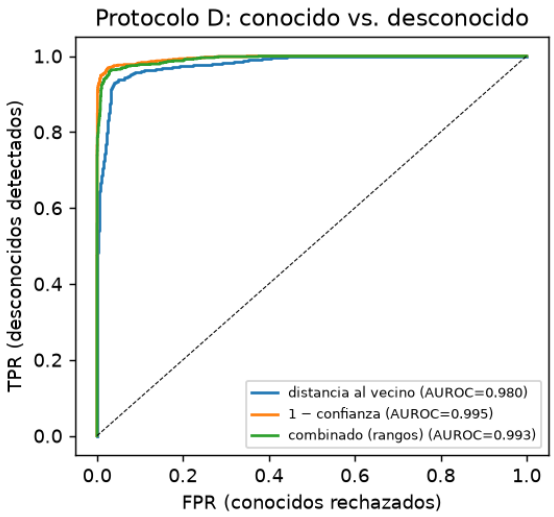


Figura 6. D variante: ROC conocido vs. desconocido.

La regresión logística está bien calibrada (ECE 0.003 en A); SVM (Platt) y Random Forest tienen ECE alto en la exploración y sus probabilidades no deben usarse crudas. En las curvas riesgo–cobertura, priorizar los casos de mayor confianza o menor incertidumbre deja el riesgo de los primeros tramos muy por debajo del global; las curvas **no son estrictamente monótonas** y en B no existe un tramo con riesgo aceptable. Desconocidos: D variante AUROC distancia 0.980, confianza 0.995, combinado 0.993; conocidos rechazados 1.51%. D estricto (sin conocidos en test, AUROC no aplica): desconocidos rechazados 77.5% (IC95 [74.31, 80.40]%), desconocidos que llegan a ACT 4.86% (IC95 [3.52, 6.69]%).

8. Criterio de aceptación: ±10° y el umbral de incertidumbre

Éxito extremo a extremo = clase correcta ∧ error circular ≤ 10°. Como el robot solo actúa en ACT, la métrica de negocio es (fracción automatizada, P(clase incorrecta o desconocido o |error| > 10° | ACT)). El score de incertidumbre está en grados pero es **heurístico**: un corte de 30° no significa error ≤ 30°. Su umbral se elige directamente por el riesgo de negocio: el mayor umbral cuyo riesgo en validación sea ≤ 2 % con ≥ 50 ACT. Los cortes altos son seguros porque la ambigüedad rotacional y la confianza ya filtran los casos peligrosos; la figura muestra el riesgo con IC de Wilson en validación (selección) y en el test de la receta (solo descriptivo).

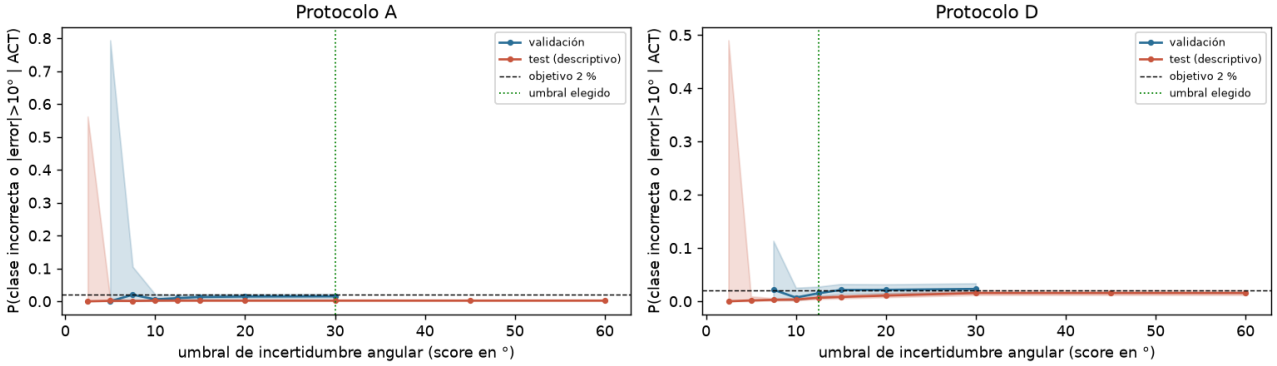


Figura 7. Riesgo entre ACT vs. umbral del score de incertidumbre (A y D variante).

Artefacto productivo: confianza ≥ 0.99, score ≤ 30.0°, distancia ≤ 19.47; en su validación 2901 ACT con error 0.72% (IC95 [0.47, 1.10]%). Esa validación no es independiente (comparte imágenes con el test de A); la evidencia independiente es la de la tabla 1. Cuando la decisión no es ACT el robot recibe {"action": "HOLD", "reason": código}.

9. Análisis de errores (receta clásica)

Prot. A: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj95	17	36	0	—
obj47	14	36	0	—
obj94	12	36	0	—
obj98	7	36	0	—

Prot. A: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj67	5	36	0	—
obj35	3	36	0	—

Prot. B: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj98	12	12	0	—
obj84	12	12	0	—
obj95	11	12	0	—
obj79	11	12	0	—
obj67	11	12	0	—
obj1	10	12	0	—

Prot. C: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj47	34	60	0	—
obj95	32	60	0	—
obj94	31	60	0	—
obj35	28	60	0	—
obj84	27	60	10	obj59
obj67	25	60	7	obj37



Figura 8. Ejemplos de fallos en C (arriba: consulta; abajo: referencia de la predicción).



Figura 9. Ejemplos de fallos en B.

Los fallos angulares se concentran en objetos simétricos o con vistas opuestas parecidas (errores de ~180° o arbitrarios) y en el arco no visto (B); los errores de clase, entre objetos de la misma familia visual. La mayoría de estos casos se envía a REVIEW.

10. Costo: latencia y tamaño

Medición	p50 (ms)	p95 (ms)	media (ms)
classic (pipeline completo, 1 imagen)	13.32	18.41	14.03
baseline píxeles 1-NN (media/imagen en lote)	—	—	0.27
resnet18 CPU (solo embedding, 1 imagen)	30.46	35.01	—
resnet18 MPS (solo embedding, 1 imagen)	15.69	19.87	—

Artefacto clásico: 9.4 MB. Pesos ResNet18 fp32: 44.7 MB (más la dependencia de PyTorch). La línea base se mide como media por imagen de una búsqueda 1-NN en lote (sin percentiles).

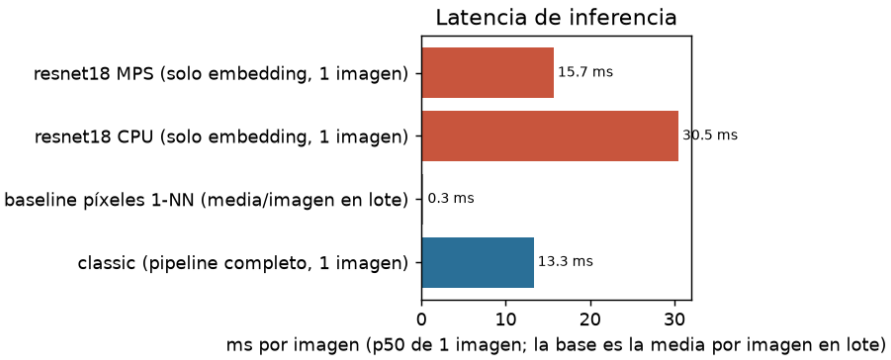


Figura 10. Latencia por imagen.

¿Justifica la brecha el costo? Con la misma receta, ResNet18 mejora la exactitud de clase en B (99.67% vs 97.00%) y C (99.98% vs 99.12%) y el MAE angular, pero tampoco habilita automatizar B ni C. En A: ACT 0.0% con error N/A (ResNet18) vs 92.2% con 0.21% (clásica): con la misma receta, ResNet18 no alcanza en su validación un riesgo ≤ 2 % con ≥ 50 ACT (mínimo con ≥ 50 ACT en A: 3.80%), así que su automatización queda desactivada pese a su mayor exactitud bruta — su score de incertidumbre (misma definición, otro espacio) separa peor los fallos angulares. Solo el embedding ResNet18 ya cuesta más en CPU que el pipeline clásico completo y añade ~45 MB de pesos más PyTorch. Producción = receta clásica; ResNet18 queda como referencia y candidata si el piloto en planta muestra una brecha mayor.

11. Model card

Uso previsto

Identificar el objeto (SKU) de una imagen de estación, estimar su ángulo de rotación en el plano [0, 360) con un score de incertidumbre en grados, y devolver las vistas de referencia más parecidas como evidencia. La salida incluye una decisión ACT / REVIEW / REJECT: el robot solo recibe un comando `PICK` con ángulo cuando la decisión es ACT; en cualquier otro caso recibe `HOLD` y el caso va a cola humana. ACT no garantiza acierto: el riesgo residual medido se reporta abajo.

Modelo (receta congelada)

• Receta `classic-logreg-v1` (`src/vision/recipe.py`): HSV(16x4x4)+HOG(64px,9or,8x8)+LBP(u8,2x2)+Hu → StandardScaler → PCA(150) → `logreg` {"C": 1.0}. Clasificador elegido en la exploración por exactitud media de validación.

• Ángulo: recuperación condicionada al objeto; k de interpolación elegido en validación (artefacto: k = 1).

• Score de incertidumbre angular: separación angular equivalente a la distancia al vecino más cercano según la curva distancia-vs-ángulo del objeto. Es un score heurístico en grados, no una cota del error; su umbral se elige para que P(clase incorrecta o |error| > 10° | ACT) ≤ 2 % en validación.

• Novedad: distancia al vecino más cercano en el espacio PCA.

• Umbrales del artefacto: confianza ≥ 0.99, score de incertidumbre ≤ 30.0°, distancia de desconocido ≤ 19.47; elegidos en validación (90 conocidos paso 10° + 10 pseudo-desconocidos): 2901 ACT, error 0.72% (IC95 [0.47, 1.10]%). Esa validación comparte imágenes con el test del protocolo A, por lo que no es una estimación independiente. Ajustables en caliente vía `PUT /v1/admin/thresholds` (validados: finitos y en rango).

• Clases marcadas con ambigüedad rotacional (→ REVIEW): obj47, obj67, obj84, obj94, obj95, obj98.

• Artefacto: 9.4 MB, SHA-256 `19cbc8a4516b0ecb`…, commit `3aa0bbbfc3` (árbol con cambios sin commit: True); latencia p50 ≈ 13.3 ms/imagen en CPU.

Datos

• COIL-100 (Columbia): 100 objetos × 72 vistas (paso 5°), 128×128 RGB, fondo oscuro y luz controlada. Hash de versión de datos: `e9e73124fbf0e964`…. Semilla 42.

• El artefacto usa las 7.200 vistas, así que no tiene test propio: sus métricas esperadas son las de la receta, evaluada en cada protocolo con test independiente (tabla siguiente).

Métricas de la receta (test independiente por protocolo, una evaluación)

Desconocidos — D estricto (90 conocidos con todas sus vistas; test = 720 vistas de 10 desconocidos): rechazados 77.5% (IC95 [74.31, 80.40]%), llegan a ACT 4.86% (IC95 [3.52, 6.69]%). D variante (mixto): AUROC combinado 0.993, conocidos rechazados 1.51%.

Éxito e2e = clase correcta y error angular circular ≤ 10° (tolerancia de agarre). *Error entre ACT* = fracción de acciones del robot que serían empaque equivocado, objeto desconocido aceptado o agarre fallido. N/A = la receta no autorizó ninguna acción (automatización desactivada por falta de evidencia en validación).

Limitaciones conocidas

• Dataset de laboratorio: fondo oscuro uniforme, iluminación fija, cámara fija, un solo eje de rotación, sin oclusión, sin desenfoque por movimiento, sin variación de escala. El desempeño en planta no está demostrado.

• Objetos rotacionalmente simétricos o con vistas opuestas parecidas: el ángulo es intrínsecamente ambiguo; el sistema los envía a REVIEW.

• Ángulos nunca vistos (protocolo B, arco ciego de 60°) y pocas vistas por SKU (protocolo C, 12 vistas): la receta desactiva la automatización (todo a REVIEW).

• Desconocidos casi duplicados de un conocido (misma familia de empaque, p. ej. obj61 ≈ obj92) pueden aceptarse como el conocido y llegar a ACT.

• El score de incertidumbre angular no es una probabilidad ni una cota; solo su umbral está validado empíricamente.

Cuándo NO usarlo

• Con cámaras, fondos o iluminación distintos sin re-captura de referencias y recalibración de umbrales.

• Para rotaciones fuera del plano (vuelcos), objetos parcialmente ocultos o varios objetos en el cuadro.

• Como única barrera de seguridad: el robot debe mantener sus propias verificaciones (peso, código de barras, sensores de agarre).

• Para SKUs nuevos sin pasar por staging (`POST /v1/skus/stage`: ≥ 12 vistas cubriendo ≥ 300°, métricas leave-one-out) y promoción explícita.

Recomendaciones para planta

Piloto en sombra (el robot no actúa; 100 % revisión humana) para recalibrar umbrales con datos reales; aumentación (brillo, blur, ruido, escala) y captura de referencias por estación; monitoreo de la tasa ACT/REVIEW/REJECT, de la distancia de novedad y de las razones de REVIEW; re-entrenamiento versionado con hash de datos, SHA del artefacto y registro en MLflow.