Reto 2 — Visión por computador en COIL-100

Identificación de objeto, estimación de ángulo con incertidumbre y recuperación de vistas similares. Modelo productivo **vision-1.0.0** · hash de datos `e9e73124fbf0e964…` · generado 2026-10-24.

1. Resumen ejecutivo

El modelo productivo es **clásico**: histogramas HSV + HOG + LBP + momentos de Hu → estandarización → PCA(150) → **logreg** {"C": 1.0}, elegido por exactitud media de validación en los cuatro protocolos. El ángulo se estima por recuperación condicionada al objeto, con una incertidumbre expresada en grados, y una regla de decisión ACT / REVIEW / REJECT garantiza que el robot solo reciba ángulos confiables. La tolerancia de agarre de ±10° se traduce en la métrica de negocio **éxito extremo a extremo** (clase correcta y error circular ≤ 10°), reportada junto a la **fracción automatizada** y el **error entre las decisiones ACT**.

Protocolo	Exactitud	MAE ángulo	≤10°	Éxito e2e	% ACT	Error | ACT	AUROC desc.
A · Interpolación	99.97%	2.71°	98.1%	98.1%	92.1%	0.21%	—
B · Sector ciego 60°	97.00%	67.47°	16.9%	16.4%	0.0%	0.00%	—
C · Escasez (12 vistas)	99.12%	9.39°	89.9%	89.1%	0.0%	0.00%	—
D · Objeto desconocido	100.00%	2.63°	98.5%	98.5%	76.3%	1.46%	0.991

Lectura: en el régimen operativo (A: referencias densas; D: con objetos desconocidos mezclados) el sistema automatiza 92.1% / 76.3% de los casos con error entre ACT de 0.21% / 1.46%. En B (arco ciego) y C (12 vistas) la apariencia no basta para un ángulo confiable y el sistema lo detecta: la mayoría de casos va a REVIEW en lugar de generar agarres fallidos. Los desconocidos se separan con AUROC 0.991; solo 5.14% de las vistas de objetos desconocidos llega a ACT.

2. Análisis del dataset

100 objetos × 72 vistas (paso exacto de 5°), 128×128 RGB, fondo oscuro casi uniforme (mediana del borde ≈ 25/255) e iluminación controlada. Propiedades que condicionan el diseño: (i) la clase es separable en laboratorio, el riesgo está en el ángulo; (ii) objetos **rotacionalmente simétricos** (latas, tazas, donas, frascos) cuyo ángulo es intrínsecamente ambiguo; (iii) objetos con vistas a 180° parecidas; (iv) familias de empaques casi duplicadas.

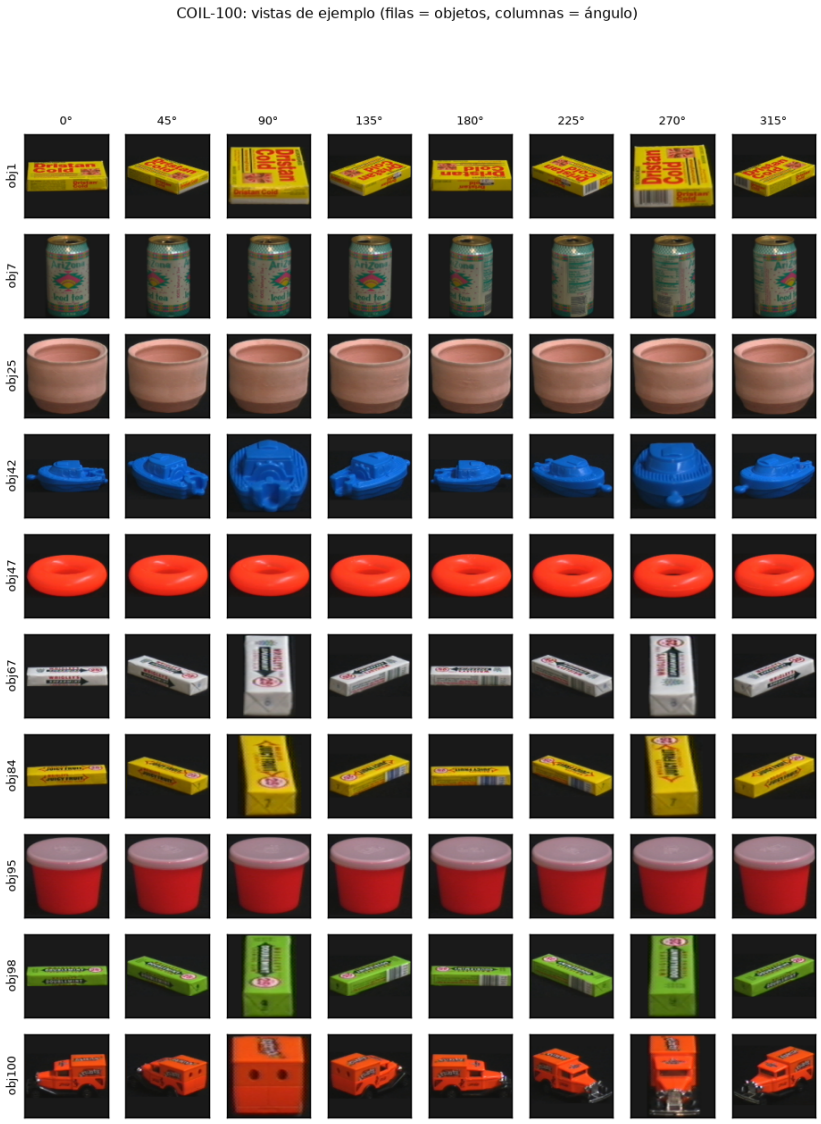


Figura 1. Vistas de ejemplo (filas: objetos; columnas: ángulo).

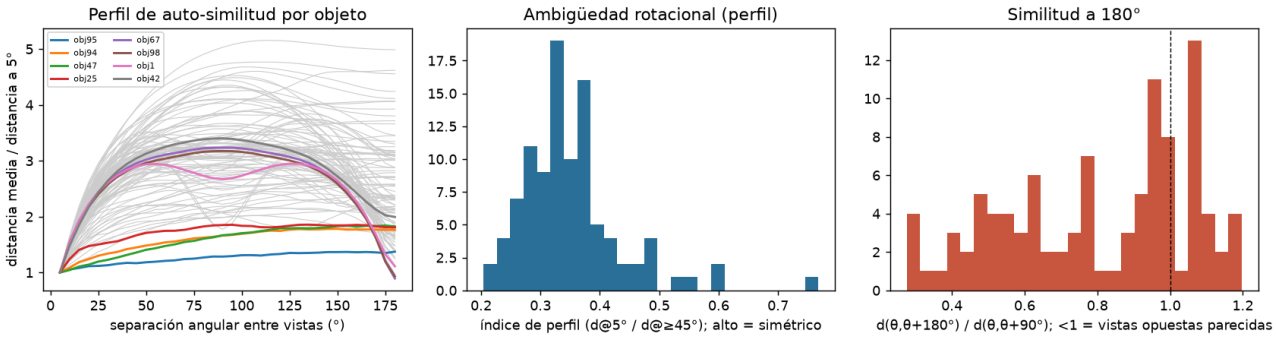


Figura 2. Izquierda: distancia media entre vistas vs. separación angular (plana = simétrico). Centro: índice de ambigüedad por objeto. Derecha: razón d(180°)/d(90°) (<1 = vistas opuestas parecidas).

Objetos más ambiguos según el índice de perfil: obj95 (0.77), obj94 (0.59), obj47 (0.59), obj25 (0.55), obj50 (0.53), obj34 (0.49), obj7 (0.48), obj86 (0.48). Tratamiento: bandera *rotational_ambiguity* por instancia (vista de referencia lejana casi tan parecida como la mejor) y por clase en el modelo productivo (clases: obj47, obj67, obj84, obj94, obj95, obj98) → REVIEW.

Objeto A	Objeto B	Dist. mínima inter-objeto	Dist. típica vista adyacente
obj61	obj92	10.99	7.45
obj29	obj32	15.77	9.11
obj47	obj94	17.94	5.06
obj67	obj84	19.00	14.58

Objeto A	Objeto B	Dist. mínima inter-objeto	Dist. típica vista adyacente
obj15	obj91	19.25	13.88
obj1	obj15	19.81	13.35

Laboratorio vs. planta. En planta habrá cinta con textura y reflejos, iluminación variable, oclusión, desenfoque por movimiento, pose y escala de cámara variables y empaques nuevos. Mitigación: aumentación (brillo, contraste, blur, ruido, escala, recortes) y captura de referencias por estación; compuerta de calidad determinista previa al modelo; recalibración de umbrales con datos reales; piloto en sombra con revisión humana antes de habilitar ACT; monitoreo de deriva.

3. Metodología

Protocolo	Train / objeto	Test	Validación (solo dentro de train)
A Interpolación	0,10,…,350 (36)	5,15,…,355 (36)	fit paso 20°, val resto
B Sector ciego	60	arco contiguo 60° (12); inicio aleatorio, semilla 42	arco de 60° dentro de train
C Escasez	1 cada 30° (12)	las otras 60	fit paso 60°, val resto
D Desconocido	90 objetos, paso 10°	vistas impares de los 90 + todas las de 10 desconocidos	10 pseudo-desconocidos (semilla 43)

Objetos desconocidos en D: obj9, obj10, obj20, obj42, obj61, obj69, obj72, obj83, obj95, obj97. Se comparan cuatro clasificadores (kNN, regresión logística, SVM RBF con Platt, Random Forest) con una rejilla pequeña; el mejor hiperparámetro por clasificador y el mejor clasificador se eligen en validación y luego se evalúa **una sola vez** en test. Los umbrales (confianza mínima, incertidumbre angular máxima, distancia de desconocido) también se fijan en validación: máxima cobertura con error entre ACT ≤ 2 %; distancia de desconocido por Youden con pseudo-desconocidos; si ningún umbral cumple el objetivo, la automatización se desactiva. En C la validación no tiene vistas a ≤15° de las de ajuste, por lo que el umbral angular usa el prior 5° (mitad de la tolerancia). Todo queda en MLflow (sqlite:///mlflow.db, experimento vision-coil100) con parámetros, métricas por protocolo, hash de datos y artefactos.

4. Resultados por protocolo

Comparación obligatoria: modelo clásico seleccionado vs. línea base (1-NN en píxeles crudos 32×32, sin rechazo) vs. referencia moderna (ResNet18 ImageNet congelada + mismo pipeline).

Prot.	Modelo	Exactitud	MAE ángulo	Éxito e2e	% ACT	Error | ACT
A	Clásico (prod.)	99.97%	2.71°	98.1%	92.1%	0.21%
A	Base: píxeles 1-NN	99.97%	5.93°	97.6%	100.0%	2.42%
A	ResNet18 congelada	100.00%	1.98°	98.8%	71.8%	0.31%
B	Clásico (prod.)	97.00%	67.47°	16.4%	0.0%	0.00%
B	Base: píxeles 1-NN	92.92%	61.22°	28.6%	100.0%	71.42%
B	ResNet18 congelada	99.67%	49.41°	15.8%	0.0%	0.00%
C	Clásico (prod.)	99.12%	9.39°	89.1%	0.0%	0.00%
C	Base: píxeles 1-NN	97.38%	14.02°	74.3%	100.0%	25.72%
C	ResNet18 congelada	99.95%	7.68°	87.3%	0.0%	0.00%
D	Clásico (prod.)	100.00%	2.63°	98.5%	76.3%	1.46%
D	Base: píxeles 1-NN	100.00%	5.94°	97.8%	100.0%	2.19%
D	ResNet18 congelada	100.00%	1.95°	99.0%	59.2%	0.34%

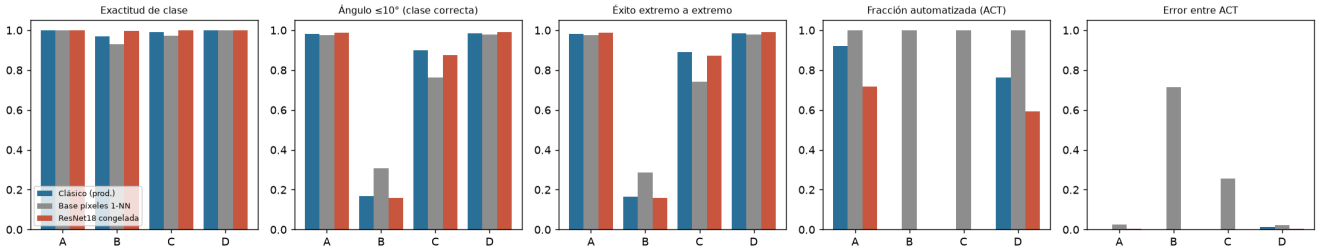


Figura 3. Métricas por protocolo y modelo.

Todos los clasificadores clásicos (test; * = elegido en validación para ese protocolo):

Prot.	Clasificador	Exactitud	MAE°	Éxito e2e	% ACT	Error|ACT	ECE	fit (s)
A	knn	99.78%	2.66	97.9%	93.0%	0.30%	0.002	0.3
A	logreg *	99.97%	2.71	98.1%	92.1%	0.21%	0.014	0.5
A	svm_rbf	100.00%	2.71	98.1%	92.2%	0.21%	0.539	8.7
A	random_forest	99.86%	2.71	97.9%	90.4%	0.25%	0.355	7.8
B	knn	91.67%	64.31	16.4%	0.2%	66.67%	0.083	0.6
B	logreg *	97.00%	67.47	16.4%	0.0%	0.00%	0.018	0.9
B	svm_rbf	96.17%	66.26	16.4%	0.0%	0.00%	0.499	15.5
B	random_forest	93.00%	66.07	16.4%	0.2%	66.67%	0.464	14.0
C	knn	97.78%	9.03	88.1%	0.1%	0.00%	0.022	0.2
C	logreg *	99.12%	9.39	89.1%	0.0%	0.00%	0.018	0.2
C	svm_rbf	96.78%	9.22	87.2%	0.1%	0.00%	0.736	1.9
C	random_forest	96.85%	9.00	87.3%	0.1%	0.00%	0.515	2.7
D	knn	99.72%	2.58	98.2%	77.8%	3.34%	0.003	0.4
D	logreg *	100.00%	2.63	98.5%	76.3%	1.46%	0.001	0.5
D	svm_rbf	100.00%	2.63	98.5%	76.8%	2.07%	0.511	8.8
D	random_forest	99.72%	2.63	98.2%	77.6%	3.16%	0.352	6.7

Referencia moderna ResNet18 (test):

Prot.	Clasificador	Exactitud	MAE°	Éxito e2e	% ACT	Error|ACT	ECE	fit (s)
A	knn *	100.00%	1.98	98.8%	71.8%	0.31%	0.000	0.1
A	logreg	100.00%	1.98	98.8%	71.7%	0.31%	0.004	0.3
A	svm_rbf	100.00%	1.98	98.8%	71.8%	0.31%	0.657	4.4
A	random_forest	99.97%	1.98	98.8%	71.8%	0.31%	0.193	6.6
B	knn	99.00%	48.70	15.8%	0.0%	0.00%	0.010	0.4
B	logreg *	99.67%	49.41	15.8%	0.0%	0.00%	0.015	0.7
B	svm_rbf	99.67%	49.41	15.8%	0.0%	0.00%	0.564	8.9
B	random_forest	98.08%	48.92	15.8%	0.0%	0.00%	0.285	10.8
C	knn	99.77%	7.65	87.2%	0.0%	0.00%	0.029	0.1
C	logreg *	99.95%	7.68	87.3%	0.0%	0.00%	0.052	0.2
C	svm_rbf	99.88%	7.65	87.3%	0.0%	0.00%	0.841	1.4
C	random_forest	99.97%	7.68	87.4%	0.0%	0.00%	0.372	2.1
D	knn *	100.00%	1.95	99.0%	59.2%	0.34%	0.000	0.1
D	logreg	100.00%	1.95	99.0%	59.2%	0.34%	0.019	0.3
D	svm_rbf	100.00%	1.95	99.0%	59.2%	0.34%	0.630	4.4
D	random_forest	100.00%	1.95	99.0%	59.2%	0.34%	0.185	5.7

5. Ángulo

Métrica: error circular min(|a−b|, 360−|a−b|). Se reporta MAE, mediana y fracción ≤ 10° sobre las predicciones con clase correcta. Alternativas comparadas: ángulo del vecino más cercano (sin interpolar) vs. interpolación con 2 y 3 vecinos.

Protocolo	Vecinos	MAE (°)	Mediana (°)	≤10°
A	1	6.07	5.00	98.2%
A	2	2.71	1.32	98.1%
A	3	3.13	1.86	98.3%
B	1	66.47	25.00	28.6%
B	2	67.47	26.60	16.9%
B	3	68.57	27.74	15.8%
C	1	13.13	10.00	70.5%
C	2	9.39	4.72	89.9%
C	3	10.45	5.33	85.8%

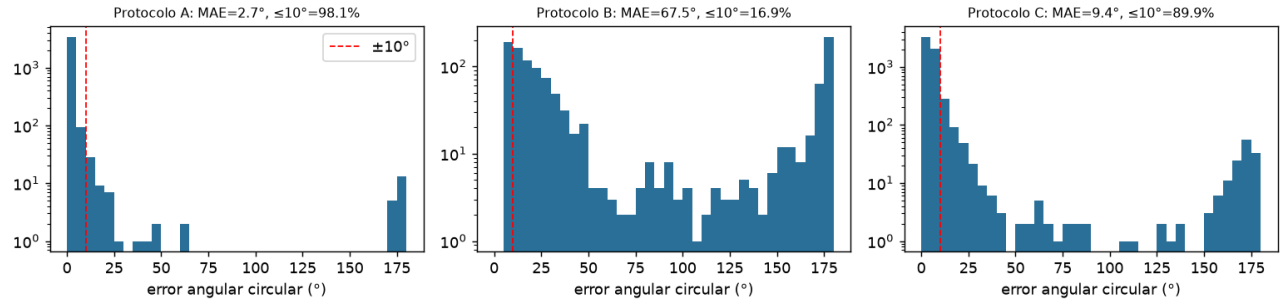


Figura 4. Histograma del error angular circular (escala log); línea roja = ±10°.

6. Rechazo y calibración: ¿es la confianza una base válida para decidir?

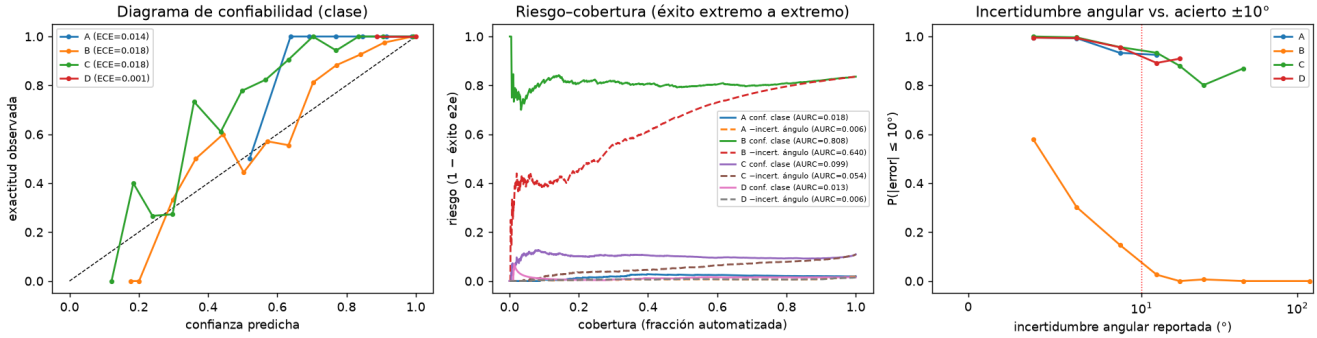


Figura 5. Diagrama de confiabilidad (clase), curvas riesgo–cobertura y P(|error| ≤ 10°) vs. incertidumbre angular.

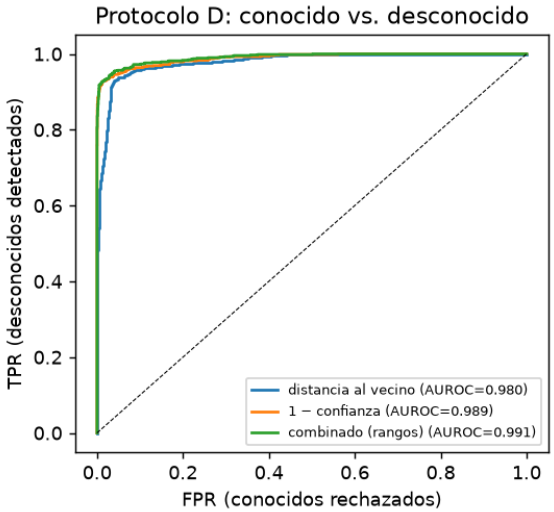


Figura 6. Protocolo D: ROC conocido vs. desconocido.

La regresión logística está bien calibrada (ECE bajo en los cuatro protocolos), mientras que SVM (Platt) y Random Forest tienen ECE alto: sus probabilidades no deben usarse crudas para decidir. Las curvas riesgo–cobertura bajan monótonamente al exigir más confianza / menos incertidumbre, por lo que existe un umbral operable. En D: AUROC distancia 0.980, confianza 0.989, combinado 0.991; con el umbral de validación se rechaza 71.2% de las vistas desconocidas (TPR), 94.9% no llega a ACT, y solo 1.51% de las vistas conocidas se rechaza.

7. Criterio de aceptación (±10° → métrica de negocio)

Éxito extremo a extremo = clase correcta ∧ error circular ≤ 10°. Como el robot solo actúa en ACT, la métrica de negocio es el par (fracción automatizada, error entre ACT). El umbral de incertidumbre angular está en grados y se elige para que el error entre ACT ≤ 2 % en validación.

Prot.	Modelo	Éxito e2e	% ACT	Error|ACT	Umbral incert.	Automatización
A	Clásico (prod.)	98.1%	92.1%	0.21%	30.0°	sí
A	ResNet18	98.8%	71.8%	0.31%	7.5°	sí
A	Base píxeles 1-NN	97.6%	100.0%	2.42%	—	—

Prot.	Modelo	Éxito e2e	% ACT	Error|ACT	Umbral incert.	Automatización
B	Clásico (prod.)	16.4%	0.0%	0.00%	5.0°	sí
B	ResNet18	15.8%	0.0%	0.00%	5.0°	sí
B	Base píxeles 1-NN	28.6%	100.0%	71.42%	—	—
C	Clásico (prod.)	89.1%	0.0%	0.00%	5.0°	sí
C	ResNet18	87.3%	0.0%	0.00%	5.0°	sí
C	Base píxeles 1-NN	74.3%	100.0%	25.72%	—	—
D	Clásico (prod.)	98.5%	76.3%	1.46%	30.0°	sí
D	ResNet18	99.0%	59.2%	0.34%	7.5°	sí
D	Base píxeles 1-NN	97.8%	100.0%	2.19%	—	—

Umbrales del modelo productivo (validación con 10 pseudo-desconocidos): confianza ≥ 0.99, incertidumbre ≤ 30.0°, distancia de desconocido ≤ 19.47. Cuando la decisión no es ACT el robot recibe {"action": "HOLD", "reason": código} y nunca un ángulo dudoso.

8. Análisis de errores

Prot. A: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj95	17	36	0	—
obj47	14	36	0	—
obj94	12	36	0	—
obj98	7	36	0	—
obj67	5	36	0	—
obj35	3	36	0	—

Prot. B: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj98	12	12	0	—
obj95	12	12	0	—
obj84	12	12	0	—
obj96	11	12	0	—
obj94	11	12	0	—
obj47	11	12	0	—

Prot. C: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj94	31	60	0	—
obj95	29	60	0	—
obj84	25	60	10	obj59
obj47	24	60	0	—
obj67	20	60	7	obj37
obj98	20	60	2	obj75



Figura 7. Ejemplos de fallos en C (arriba: consulta; abajo: referencia de la predicción).



Figura 8. Ejemplos de fallos en B.

Los fallos angulares se concentran en objetos simétricos o con vistas opuestas parecidas (errores de ~180° o arbitrarios) y en el arco no visto (B); los errores de clase, entre objetos de la misma familia visual. Ambos tipos de caso son los que la regla de decisión envía a REVIEW.

9. Costo: latencia y tamaño

Pipeline	p50 (ms)	p95 (ms)
classic (pipeline completo)	14.84	36.10
baseline píxeles 1-NN*	0.56	—
resnet18 CPU (solo embedding)	29.91	33.48
resnet18 MPS (solo embedding)	16.58	20.61

Artefacto clásico: 9.4 MB. Pesos ResNet18 fp32: 44.7 MB (más la dependencia de PyTorch). *La línea base se mide en lote (búsqueda 1-NN sin extracción ni decisión).

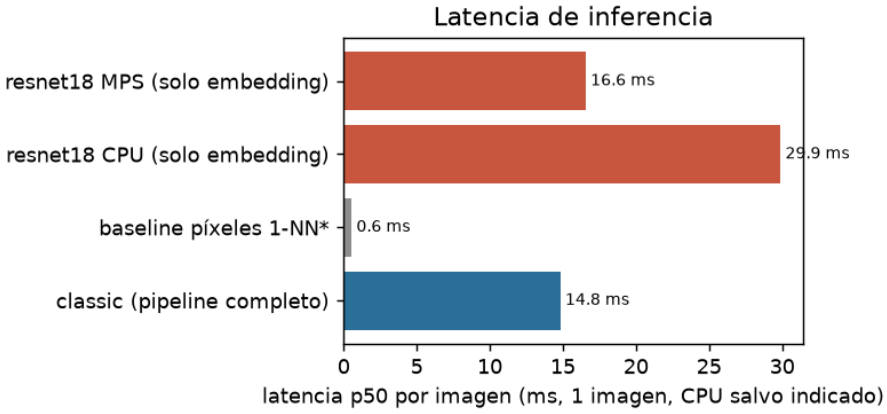


Figura 9. Latencia por imagen.

¿Justifica la brecha el costo? La referencia moderna mejora la exactitud de clase en los protocolos con brecha (B: 99.67% vs 97.00%; C: 99.95% vs 99.12%) y el MAE angular, pero no resuelve el arco ciego ni habilita automatizar C. En el régimen operativo, el clásico automatiza más (A: 92.1% vs 71.8%; D: 76.3% vs 59.2%) con error entre ACT de 0.21% / 1.46% (ResNet: 0.31% / 0.34%). Solo el embedding ResNet18 cuesta 29.9 ms p50 en CPU frente a 14.8 ms del pipeline clásico completo, y añade ~45 MB de pesos más la dependencia de PyTorch. Producción = clásico; ResNet18 queda como referencia y candidata si el piloto en planta (fondos e iluminación reales) muestra una brecha mayor, en particular en desconocidos casi duplicados.

10. Model card

Uso previsto

Identificar el objeto (SKU) de una imagen de estación, estimar su ángulo de rotación en el plano [0, 360) con una medida de incertidumbre en grados, y devolver las vistas de referencia más parecidas como evidencia. La salida incluye una decisión ACT / REVIEW / REJECT: el robot solo recibe un comando `PICK` con ángulo cuando la decisión es ACT; en cualquier otro caso recibe `HOLD` y el caso va a cola humana.

Modelo

• Familia: clásico: HSV+HOG+LBP+Hu → estandarización → PCA → logreg (ML clásico; sin redes profundas en producción).

• Clasificador: `logreg` {"C": 1.0}, elegido por exactitud media de validación en los 4 protocolos (nunca con test).

• Ángulo: recuperación condicionada al objeto (vecino más cercano + media circular ponderada de 2 vecinos); incertidumbre = separación angular equivalente a la distancia al vecino más cercano según la curva distancia-vs-ángulo del propio objeto.

• Novedad: distancia al vecino más cercano en el espacio PCA.

• Umbrales vigentes: confianza mínima 0.99, incertidumbre angular máxima 30.0°, distancia de desconocido 19.47 (elegidos en validación con 10 objetos pseudo-desconocidos; error objetivo entre ACT ≤ 2 %). Ajustables en caliente vía `PUT /v1/admin/thresholds`.

• Clases marcadas como rotacionalmente simétricas (→ REVIEW): obj47, obj67, obj84, obj94, obj95, obj98.

• Tamaño del artefacto: 9.4 MB; latencia p50 ≈ 14.8 ms/imagen en CPU.

Datos

• COIL-100 (Columbia): 100 objetos × 72 vistas (paso 5°), 128×128 RGB, fondo oscuro y luz controlada. Hash de versión de datos: `e9e73124fbf0e964`…. Semilla 42.

• El modelo productivo se entrena con las 7.200 vistas; las métricas provienen de los protocolos A–D (abajo).

Métricas (test, una sola evaluación por protocolo)

Desconocidos (D): AUROC distancia 0.980, confianza 0.989, combinado 0.991; desconocidos rechazados 71.2%, desconocidos que llegan a ACT 5.14%, conocidos rechazados 1.51%.

Éxito e2e = clase correcta y error angular circular ≤ 10° (tolerancia de agarre). *Error entre ACT* = fracción de acciones del robot que serían empaque equivocado o agarre fallido.

Limitaciones conocidas

• Dataset de laboratorio: fondo oscuro uniforme, iluminación fija, cámara fija, un solo eje de rotación, sin oclusión, sin desenfoque por movimiento, sin variación de escala. El desempeño en planta no está demostrado.

• Objetos rotacionalmente simétricos o con vistas opuestas parecidas: el ángulo es intrínsecamente ambiguo; el sistema los envía a REVIEW.

• Ángulos nunca vistos (protocolo B, arco ciego de 60°): la recuperación no puede extrapolar; casi todo va a REVIEW y la automatización se desactiva si la validación no alcanza el objetivo de error.

• Pocas vistas por SKU (protocolo C, 12 vistas): la clase es fiable pero el ángulo no alcanza la confiabilidad exigida para ACT.

• La novedad se mide por distancia en el espacio de características: un objeto desconocido muy parecido a uno conocido (misma familia de empaque) puede aceptarse como conocido.

Cuándo NO usarlo

• Con cámaras, fondos o iluminación distintos sin re-captura de referencias y recalibración de umbrales.

• Para rotaciones fuera del plano (vuelcos), objetos parcialmente ocultos o varios objetos en el cuadro.

• Como única barrera de seguridad: la decisión ACT reduce pero no elimina el error; el robot debe mantener sus propias verificaciones (peso, código de barras, sensores de agarre).

• Para SKUs nuevos sin pasar por staging (`POST /v1/skus/stage`: ≥ 12 vistas cubriendo ≥ 300°, métricas leave-one-out) y promoción explícita.

Recomendaciones para planta

Piloto en sombra (el robot no actúa; 100 % revisión humana) para recalibrar umbrales con datos reales; aumentación (brillo, blur, ruido, escala) y captura de referencias por estación; monitoreo de la tasa ACT/REVIEW/REJECT, de la distancia de novedad y de las razones de REVIEW; re-entrenamiento versionado con hash de datos y registro en MLflow.