Reto 2 — Visión por computador en COIL-100

Identificación de objeto, estimación de ángulo con incertidumbre y recuperación de vistas similares. Artefacto **vision-1.0.1** · configuración **classic-logreg-v1** · hash de datos `e9e73124fbf0e964…` · SHA modelo `4fce6c32cb4abe36…` · generado 2026-10-24.

1. Resumen ejecutivo

Solución productiva **clásica**: preprocesado robusto a ruido (mediana 3×3 + supresión de fondo) → histogramas HSV + HOG + LBP + Hu → PCA(150) → clasificador; ángulo por recuperación condicionada al objeto con un score de incertidumbre en grados; regla ACT / REVIEW / REJECT que solo habilita ACT si en validación el riesgo observado es ≤ 2 % con ≥ 50 casos y, con pseudo-desconocidos, ≤ 5 % de ellos llega a ACT. La tolerancia de ±10° se traduce en **éxito extremo a extremo** (clase correcta y error circular ≤ 10°) y en el par de negocio **fracción automatizada** / **error entre ACT**.

Cifras independientes (selección anidada: familia, hiperparámetros, k y umbrales elegidos solo con la validación interna del train de cada protocolo; test evaluado una vez):

Protocolo	Modelo	Exactitud	MAE ángulo	Éxito e2e	% ACT	n ACT	Error|ACT	IC95 Wilson
A · Interpolación	svm_rbf:C: 10.0	100.00%	2.91°	98.5%	90.3%	3251	0.09%	[0.03, 0.27]%
B · Sector ciego 60°	logreg:C: 1.0	96.17%	65.52°	28.5%	0.0%	0	N/A	N/A
C · Escasez (12 vistas)	logreg:C: 0.1	98.78%	13.01°	69.7%	0.0%	0	N/A	N/A
D estricto · desconocidos	knn:n_neighbors: 1	N/A	—	N/A	12.6%	91	100.00%	[95.95, 100.00]%
D variante · mixto	knn:n_neighbors: 1	99.63%	2.74°	98.3%	74.9%	2967	2.56%	[2.05, 3.19]%

Lectura: con referencias densas (A) se automatiza 90.3% con error entre ACT observado 0.09% (IC95 [0.03, 0.27]%). En B (arco ciego) y C (12 vistas) la política efectiva es 0 ACT: la validación no aporta evidencia suficiente. En D estricto se rechaza 71.2% de las vistas de objetos desconocidos y 12.64% llega a ACT (con la selección anidada: kNN; todas de obj61 —casi duplicado de obj92— y obj69): el criterio de validación (0 % de pseudo-desconocidos a ACT) no se trasladó al test. En la variante D el error entre ACT observado (2.56%) supera el objetivo de 2 %. La configuración desplegada (logística C=1) obtiene en A 90.3% ACT con error 0.09%, pero su familia/C se eligió con validaciones agregadas que se solapan con tests de otros protocolos (sección 5). El artefacto se entrena con las 7.200 vistas y no tiene test propio.

2. Análisis del dataset

100 objetos × 72 vistas (paso exacto de 5°), 128×128 RGB, fondo oscuro casi uniforme (mediana del borde ≈ 25/255, con ruido) e iluminación controlada. Propiedades que condicionan el diseño: (i) la clase es separable en laboratorio, el riesgo está en el ángulo; (ii) objetos **rotacionalmente simétricos** (latas, tazas, donas, frascos); (iii) en ~3/4 de los objetos la vista a 180° se parece más que la de 90°; (iv) familias de empaques casi duplicadas; (v) el fondo no es exactamente negro: el ruido de sensor en el fondo genera textura espuria si no se suprime.

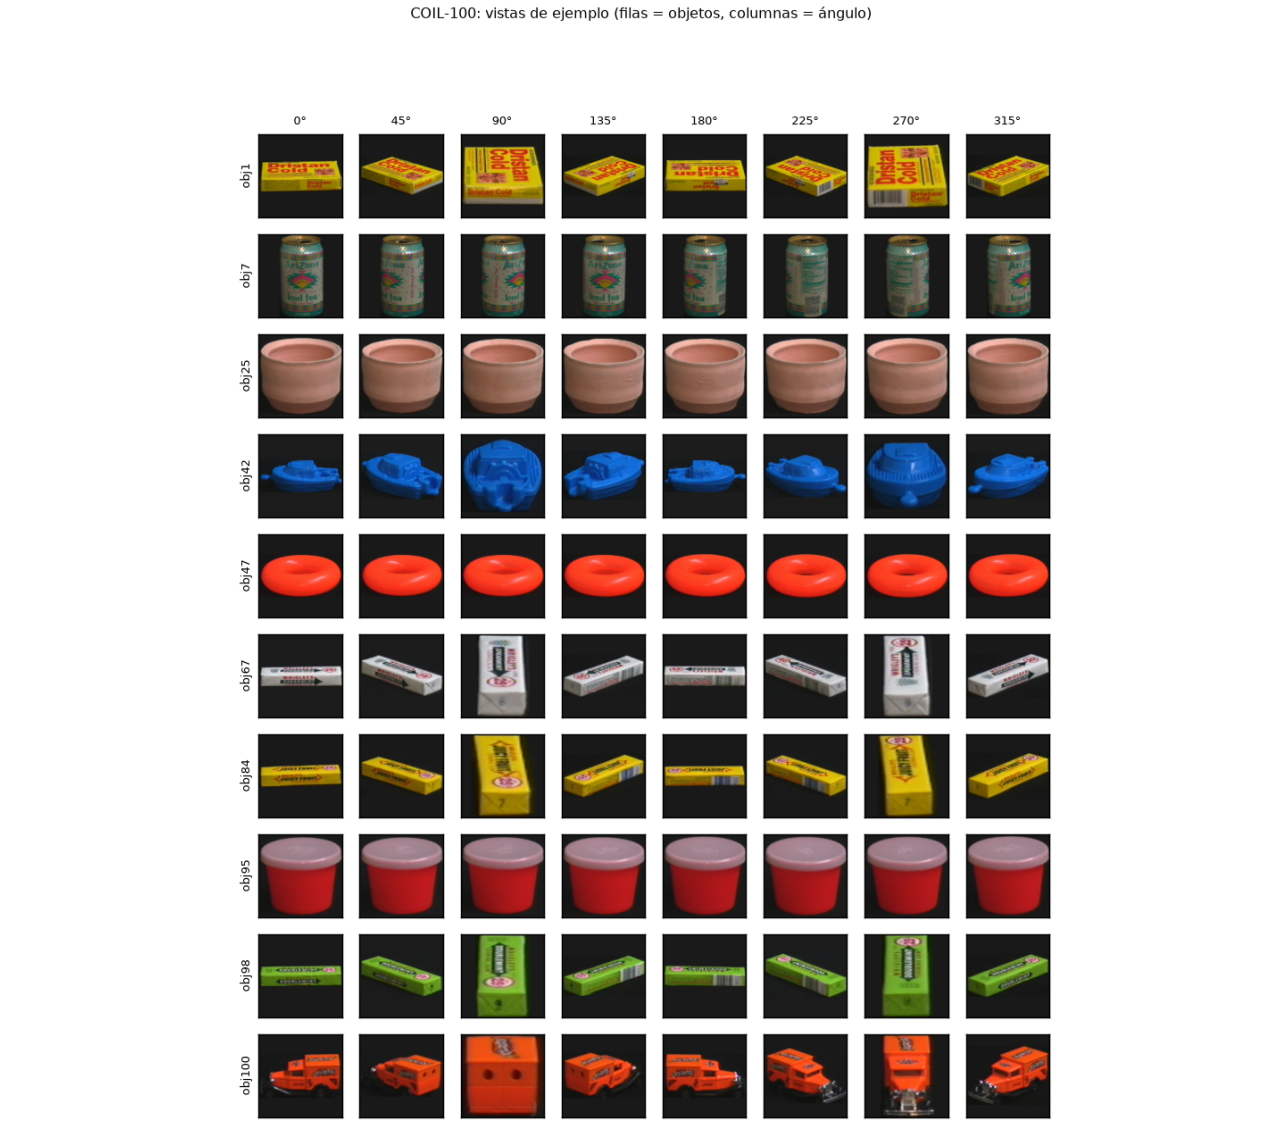


Figura 1. Vistas de ejemplo (filas: objetos; columnas: ángulo).

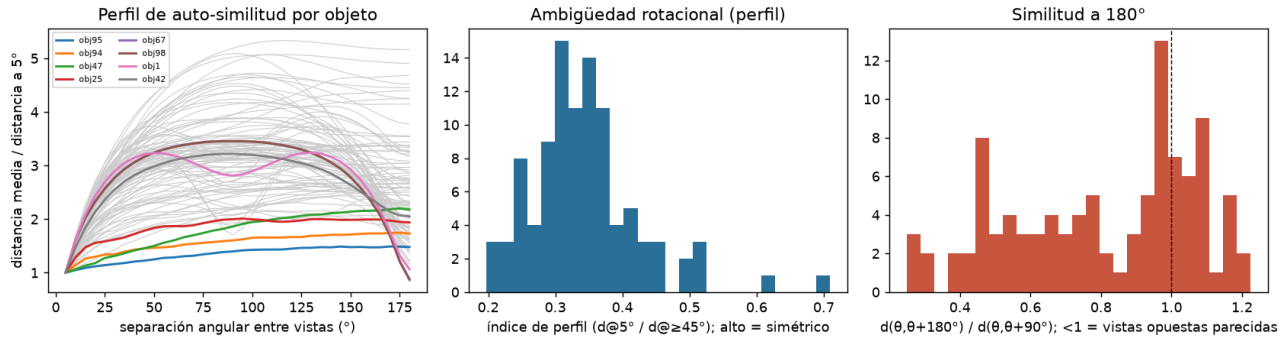


Figura 2. Izquierda: distancia media entre vistas vs. separación angular (plana = simétrico). Centro: índice de ambigüedad por objeto. Derecha: razón d(180°)/d(90°) (<1 = vistas opuestas parecidas).

Objetos más ambiguos según el índice de perfil: obj95 (0.71), obj94 (0.61), obj47 (0.52), obj25 (0.51), obj34 (0.51), obj50 (0.50), obj30 (0.48), obj58 (0.46). Tratamiento: bandera *rotational_ambiguity* por instancia, por clase (índice LOO) y para clases cuyo ángulo falla en > 25 % de su validación (artefacto: obj35, obj47, obj67, obj84, obj94, obj95, obj98) → REVIEW.

Objeto A	Objeto B	Dist. mínima inter-objeto	Dist. típica vista adyacente
obj61	obj92	10.87	7.41
obj29	obj32	16.89	8.27
obj67	obj84	17.99	13.39
obj47	obj94	19.32	3.98

Objeto A	Objeto B	Dist. mínima inter-objeto	Dist. típica vista adyacente
obj15	obj91	19.40	14.02
obj21	obj44	19.66	15.64

Laboratorio vs. planta. En planta habrá cinta con textura y reflejos, iluminación variable, oclusión, desenfoque por movimiento, pose y escala variables y empaques nuevos. Mitigación: preprocesado robusto y aumentación (sección 6), captura de referencias por estación, compuerta de calidad, recalibración con datos reales, piloto en sombra y monitoreo de deriva.

3. Metodología

Protocolo	Train / objeto	Test	Validación (solo dentro de train)
A Interpolación	0,10,…,350 (36)	5,15,…,355 (36)	fit paso 20°, val resto
B Sector ciego	60	arco contiguo 60° (12); inicio aleatorio, semilla 42	otro arco de 60° dentro de train
C Escasez	1 cada 30° (12)	las otras 60	fit paso 60°, val resto
D estricto	90 objetos, 72 vistas	solo las 720 vistas de 10 desconocidos	10 pseudo-desconocidos (semilla 43)
D variante	90 objetos, paso 10°	vistas impares de los 90 + 720 desconocidas	10 pseudo-desconocidos (semilla 43)

Desconocidos en D: obj9, obj10, obj20, obj42, obj61, obj69, obj72, obj83, obj95, obj97. **Selección anidada**: 6 candidatos (logística C∈{0.1,1,10}, SVM RBF C=10, kNN k=1, Random Forest 300); para cada uno, con la validación interna del protocolo, se eligen k angular, clases de ángulo poco fiable y umbrales; se elige el candidato con automatización habilitada y mayor cobertura de validación (desempate: exactitud). Preprocesado igual en entrenamiento e inferencia; aumentación solo en vistas de train; validación con vistas limpias + perturbadas. Riesgos con IC de Wilson 95 %. MLflow (sqlite:///mlflow.db, experimento vision-coil100) registra cada corrida anidada, desplegada y el entrenamiento final (model.joblib, SHA-256, snapshot del código, commit y versiones de librerías).

4. Selección anidada por protocolo (cifras independientes)

Validación interna de cada protocolo (* = elegido). La columna ECE (validación) muestra que la logística está bien calibrada y que SVM (Platt) y Random Forest no lo están.

A · Interpolación

Candidato	val exactitud	val ECE	val % ACT	val error|ACT	k	Autom.
logreg:C: 0.1	98.92%	0.026	71.9%	1.74%	2	sí
logreg:C: 1.0	99.00%	0.008	71.9%	1.74%	2	sí
logreg:C: 10.0	98.92%	0.004	71.9%	1.74%	2	sí
svm_rbf:C: 10.0 *	98.44%	0.586	81.6%	1.94%	2	sí
knn:n_neighbors: 1	97.14%	0.029	71.9%	1.97%	2	sí
random_forest:n_estimators: 300	96.72%	0.421	69.3%	1.76%	2	sí

B · Sector ciego 60°

Candidato	val exactitud	val ECE	val % ACT	val error|ACT	k	Autom.
logreg:C: 0.1	94.17%	0.040	0.0%	N/A	1	no
logreg:C: 1.0 *	94.75%	0.016	0.0%	N/A	1	no
logreg:C: 10.0	92.46%	0.037	0.0%	N/A	1	no
svm_rbf:C: 10.0	93.04%	0.394	0.0%	N/A	1	no
knn:n_neighbors: 1	87.58%	0.124	0.0%	N/A	1	no
random_forest:n_estimators: 300	88.38%	0.415	0.0%	N/A	1	no

C · Escasez (12 vistas)

Candidato	val exactitud	val ECE	val % ACT	val error|ACT	k	Autom.
logreg:C: 0.1 *	87.75%	0.096	0.0%	N/A	1	no
logreg:C: 1.0	87.50%	0.035	0.0%	N/A	1	no
logreg:C: 10.0	86.00%	0.043	0.0%	N/A	1	no
svm_rbf:C: 10.0	77.33%	0.656	0.0%	N/A	1	no
knn:n_neighbors: 1	76.33%	0.237	0.0%	N/A	1	no
random_forest:n_estimators: 300	80.08%	0.469	0.0%	N/A	1	no

D estricto · desconocidos

Candidato	val exactitud	val ECE	val % ACT	val error|ACT	k	Autom.
logreg:C: 0.1	100.00%	0.009	73.7%	1.32%	3	sí
logreg:C: 1.0	100.00%	0.002	73.9%	1.32%	3	sí
logreg:C: 10.0	100.00%	0.000	73.9%	1.32%	3	sí
svm_rbf:C: 10.0	99.98%	0.302	73.8%	1.32%	3	sí
knn:n_neighbors: 1 *	99.62%	0.004	74.0%	1.43%	3	sí
random_forest:n_estimators: 300	99.86%	0.295	73.6%	1.28%	3	sí

D variante · mixto

Candidato	val exactitud	val ECE	val % ACT	val error|ACT	k	Autom.
logreg:C: 0.1	98.96%	0.026	37.8%	1.54%	2	sí
logreg:C: 1.0	98.99%	0.009	37.8%	1.54%	2	sí
logreg:C: 10.0	98.99%	0.004	37.9%	1.54%	2	sí
svm_rbf:C: 10.0	98.26%	0.530	37.9%	1.54%	2	sí
knn:n_neighbors: 1 *	97.01%	0.030	37.9%	1.68%	2	sí
random_forest:n_estimators: 300	96.49%	0.398	37.9%	1.68%	2	sí

5. Configuración desplegada, línea base y referencia moderna

Salvedad: la configuración desplegada (logística C=1) se fijó con una exploración inicial que promedió validaciones de A–D; como los protocolos cubren juntos todas las imágenes, esa elección tocó imágenes que son test de otros protocolos. Sus cifras se reportan como referencia, no como estimación independiente. La línea base (1-NN en píxeles crudos 32×32) siempre actúa, por lo que en D sus decisiones sobre desconocidos cuentan como error entre ACT. ResNet18 usa la misma configuración sin aumentación.

Prot.	Modelo	Exactitud	MAE ángulo	Éxito e2e	% ACT	Error|ACT	IC95
A	Selección anidada	100.00%	2.91°	98.5%	90.3%	0.09%	[0.03, 0.27]%
A	Config. desplegada (clásica)	100.00%	2.91°	98.5%	90.3%	0.09%	[0.03, 0.27]%
A	Base píxeles 1-NN (siempre ACT)	99.97%	5.93°	97.6%	100.0%	2.42%	[1.96, 2.97]%
A	Config. desplegada + ResNet18	100.00%	1.98°	98.8%	0.0%	N/A	N/A
B	Selección anidada	96.17%	65.52°	28.5%	0.0%	N/A	N/A
B	Config. desplegada (clásica)	96.17%	65.52°	28.5%	0.0%	N/A	N/A
B	Base píxeles 1-NN (siempre ACT)	92.92%	61.22°	28.6%	100.0%	71.42%	[68.80, 73.90]%
B	Config. desplegada + ResNet18	99.67%	48.32°	27.9%	0.0%	N/A	N/A
C	Selección anidada	98.78%	13.01°	69.7%	0.0%	N/A	N/A
C	Config. desplegada (clásica)	98.83%	13.01°	69.7%	0.0%	N/A	N/A
C	Base píxeles 1-NN (siempre ACT)	97.38%	14.02°	74.3%	100.0%	25.72%	[24.63, 26.84]%
C	Config. desplegada + ResNet18	99.98%	11.35°	69.8%	0.0%	N/A	N/A
D estr.	Selección anidada	N/A	—	N/A	12.6%	100.00%	[95.95, 100.00]%
D estr.	Config. desplegada (clásica)	N/A	—	N/A	6.4%	100.00%	[92.29, 100.00]%
D estr.	Base píxeles 1-NN (siempre ACT)	N/A	—	N/A	100.0%	100.00%	[99.47, 100.00]%
D estr.	Config. desplegada + ResNet18	N/A	—	N/A	2.2%	100.00%	[80.64, 100.00]%
D	Selección anidada	99.63%	2.74°	98.3%	74.9%	2.56%	[2.05, 3.19]%
D	Config. desplegada (clásica)	100.00%	2.90°	98.6%	73.7%	0.93%	[0.64, 1.34]%
D	Base píxeles 1-NN (siempre ACT)	100.00%	5.94°	97.8%	100.0%	19.97%	[18.76, 21.25]%
D	Config. desplegada + ResNet18	100.00%	1.95°	99.0%	0.0%	N/A	N/A

Umbrales de la configuración desplegada por protocolo (elegidos en validación):

Protocolo	k (val)	Conf. mín.	Incert. máx.	Dist. desc.	Val: n ACT	Val: error|ACT	Val: desc.→ACT	Autom.
A · Interpolación	2	0.40	15.0°	38.06	2587	1.74%	N/A	sí
B · Sector ciego 60°	1	0.80	desactivada	39.73	0	N/A	N/A	no
C · Escasez (12 vistas)	1	0.90	desactivada	43.86	0	N/A	N/A	no
D estricto · desconocidos	3	0.95	30.0°	23.08	5318	1.32%	0.00%	sí

Protocolo	k (val)	Conf. mín.	Incert. máx.	Dist. desc.	Val: n ACT	Val: error|ACT	Val: desc.→ACT	Autom.
D variante · mixto	2	0.90	12.5°	24.42	1361	1.54%	0.00%	sí

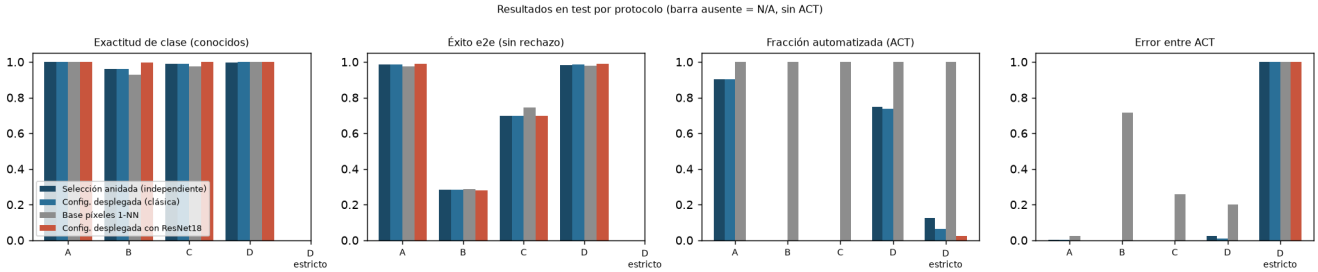


Figura 3. Resultados por protocolo (barra ausente = N/A, sin ACT).

6. Robustez a perturbaciones

En la prueba de punta a punta, ruido gaussiano casi imperceptible (σ=1–4) sobre el fondo creaba textura espuria y disparaba la distancia de novedad (REJECT). Corrección: mediana 3×3 + máscara sobre gris suavizado + fondo a 0, igual en entrenamiento e inferencia; aumentación de train (ruido σ≤6, brillo ×0.8–1.2, blur leve) y umbrales calibrados con validación perturbada. Evaluación: el modelo ya ajustado de la configuración desplegada, con sus umbrales, sobre el test perturbado (semillas fijas). σ=8 y brillo ×0.7/×1.3 están fuera del rango de aumentación.

Protocolo A (conocidos)

Perturbación	Exactitud	MAE ángulo	Éxito e2e	% ACT	n ACT	Error|ACT	IC95
limpia	100.00%	2.91°	98.5%	90.3%	3250	0.09%	[0.03, 0.27]%
ruido σ=2	100.00%	3.15°	97.6%	90.3%	3250	0.15%	[0.07, 0.36]%
ruido σ=4	100.00%	3.97°	95.8%	89.8%	3233	1.11%	[0.81, 1.54]%
ruido σ=8	99.97%	6.12°	91.9%	85.5%	3078	2.40%	[1.92, 3.01]%
brillo ×0.7	99.94%	7.67°	91.7%	80.6%	2902	1.48%	[1.10, 1.99]%
brillo ×1.3	100.00%	5.50°	92.9%	86.5%	3114	1.67%	[1.28, 2.18]%
blur σ=1	100.00%	3.24°	96.9%	90.0%	3239	0.49%	[0.30, 0.80]%

D estricto (desconocidos)

Perturbación	Desconocidos rechazados	Desconocidos a ACT	IC95
limpia	71.2%	6.39%	[4.82, 8.42]%
ruido σ=2	71.0%	6.25%	[4.70, 8.26]%
ruido σ=4	72.1%	6.11%	[4.58, 8.10]%
ruido σ=8	75.6%	5.97%	[4.46, 7.95]%
brillo ×0.7	82.9%	6.11%	[4.58, 8.10]%
brillo ×1.3	70.6%	5.56%	[4.11, 7.48]%
blur σ=1	74.4%	5.83%	[4.34, 7.79]%

Lectura honesta: dentro del rango aumentado (ruido σ≤4, blur σ=1) la exactitud y la cobertura cambian poco. Fuera del rango (σ=8, brillo ×0.7/×1.3) el MAE angular crece, la cobertura baja y el riesgo observado entre ACT sube (puede superar el 2 %; ver IC). La fracción de desconocidos que llega a ACT no es cero y se mantiene en el mismo orden bajo perturbación. En planta, variaciones de iluminación mayores exigen ampliar la aumentación y recalibrar.

7. Ángulo

Métrica: error circular min(|a–b|, 360–|a–b|), con MAE y fracción ≤ 10° sobre predicciones con clase correcta. Alternativas comparadas en validación: copiar el ángulo del vecino (k=1) o interpolar con 2–3 vecinos; interpolar ayuda con referencias cercanas (A, D) y no con brechas grandes (B, C).

Protocolo	k	val ≤10°	val MAE
A	1	79.0%	16.20
A	2	92.3%	9.87
A	3	91.8%	10.89
B	1	27.1%	61.90

Protocolo	k	val ≤10°	val MAE
B	2	15.9%	62.91
B	3	15.3%	63.93
C	1	0.0%	53.09
C	2	0.0%	53.09
C	3	0.0%	53.09
D_strict	1	96.4%	7.22
D_strict	2	96.6%	3.99
D_strict	3	96.8%	4.39
D	1	77.7%	17.27
D	2	91.2%	11.06
D	3	90.6%	12.12

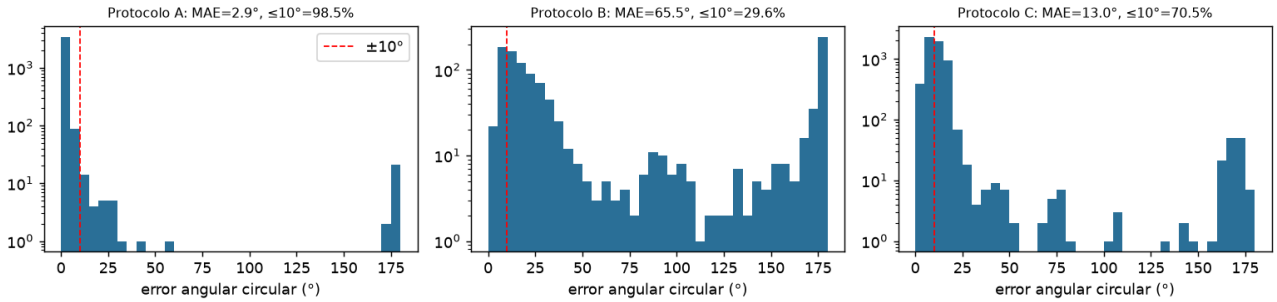


Figura 4. Error angular circular (configuración desplegada, escala log); rojo = ±10°.

8. Rechazo y calibración

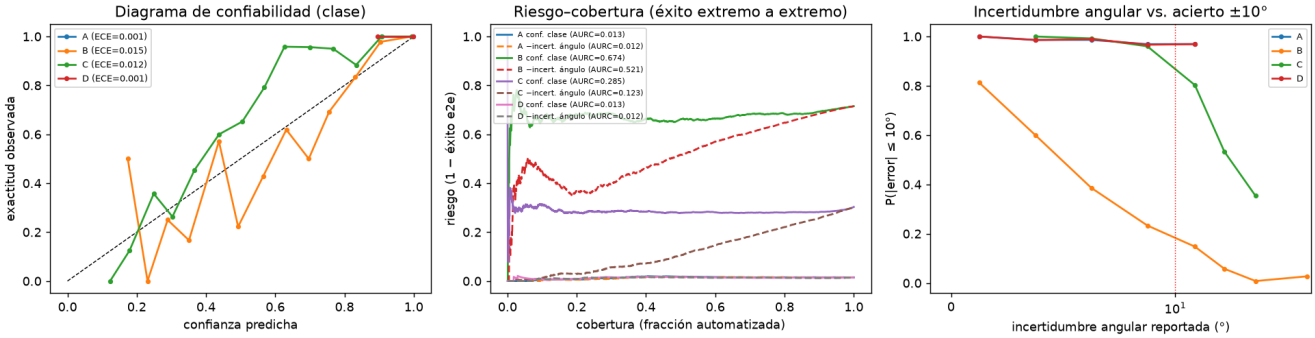


Figura 5. Confiabilidad (clase), riesgo–cobertura y P(|error| ≤ 10°) vs. score de incertidumbre.

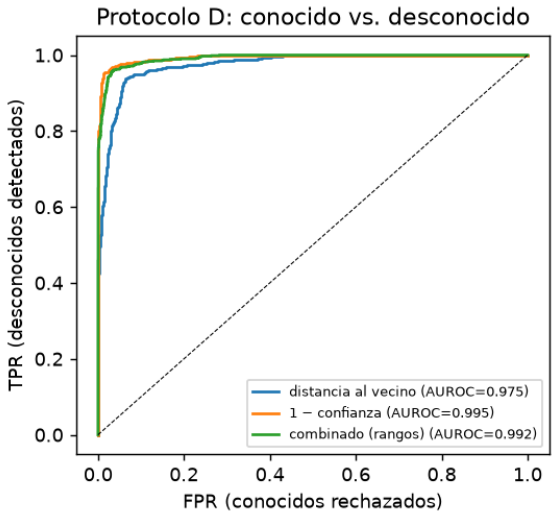


Figura 6. D variante: ROC conocido vs. desconocido (configuración desplegada).

Las curvas riesgo–cobertura bajan al priorizar mayor confianza o menor incertidumbre pero **no son estrictamente monótonas**, y en B no hay tramo con riesgo aceptable. Criterio explícito de desconocidos: ≤ 5 % de

pseudo-desconocidos de validación (≥ 100 vistas) pueden llegar a ACT. Selección anidada — D variante: AUROC combinado 0.975, conocidos rechazados 1.79%; D estricto (AUROC no aplica): rechazados 71.2% (IC95 [67.84, 74.44]%), llegan a ACT 12.64% (IC95 [10.41, 15.27]%).

9. Criterio de aceptación: ±10° y el umbral de incertidumbre

Éxito extremo a extremo = clase correcta ∧ error circular ≤ 10°; métrica de negocio = (fracción automatizada, P(clase incorrecta o desconocido o |error| > 10° | ACT)). El score de incertidumbre está en grados pero es **heurístico**: un corte de 30° no significa error ≤ 30°. El umbral se elige como el mayor cuyo riesgo observado en validación es ≤ 2 % con ≥ 50 ACT. En A, una vez aplicados la ambigüedad rotacional y la confianza, subir el corte por encima de ~10–15° añade pocos ACT y cambia poco el riesgo observado; en D el riesgo observado crece con el corte. Son observaciones sobre estos datos, no garantías.

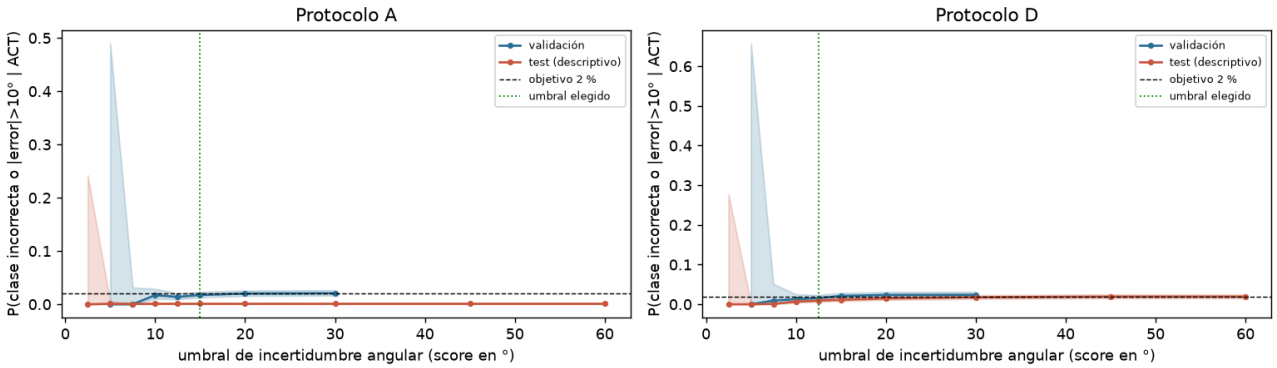


Figura 7. Riesgo entre ACT (IC Wilson) vs. umbral del score: validación (selección) y test (descriptivo).

Artefacto productivo: confianza ≥ 0.99, score ≤ 30.0°, distancia ≤ 19.84; en su validación 5693 ACT con error 1.81% (IC95 [1.49, 2.19]%). Cuando la decisión no es ACT el robot recibe {"action": "HOLD", "reason": código}.

10. Análisis de errores

Prot. A: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj95	11	36	0	—
obj94	10	36	0	—
obj98	9	36	0	—
obj47	6	36	0	—
obj84	6	36	0	—
obj67	5	36	0	—

Prot. B: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj98	12	12	0	—
obj1	11	12	0	—
obj96	11	12	0	—
obj84	11	12	0	—
obj66	11	12	0	—
obj79	11	12	0	—

Prot. C: objeto	Fallos e2e	Vistas test	Errores de clase	Confundido con
obj47	36	60	0	—
obj95	32	60	0	—
obj94	32	60	0	—
obj84	30	60	11	obj51
obj50	25	60	0	—
obj67	25	60	6	obj97



Figura 8. Ejemplos de fallos en C (arriba: consulta; abajo: referencia de la predicción).

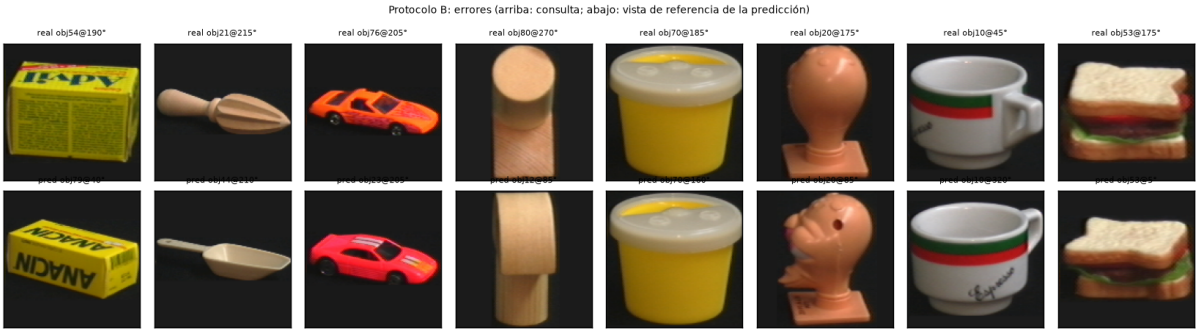


Figura 9. Ejemplos de fallos en B.

Los fallos angulares se concentran en objetos simétricos o con vistas opuestas parecidas y en el arco no visto (B); los errores de clase, entre objetos de la misma familia visual. La mayoría de estos casos se envía a REVIEW.

11. Costo: latencia y tamaño

Medición	p50 (ms)	p95 (ms)	media (ms)
classic (pipeline completo, 1 imagen)	18.02	24.61	16.82
baseline píxeles 1-NN (media/imagen en lote)	—	—	0.30
resnet18 CPU (solo embedding, 1 imagen)	26.97	31.20	—
resnet18 MPS (solo embedding, 1 imagen)	18.79	30.65	—

Artefacto clásico: 17.6 MB (incluye referencias aumentadas y el snapshot de código). Pesos ResNet18 fp32: 44.7 MB (+ PyTorch). La línea base se mide como media por imagen en lote.

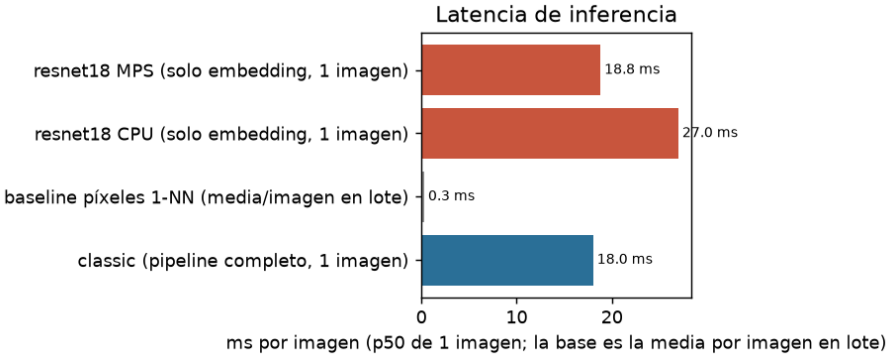


Figura 10. Latencia por imagen.

¿Justifica la brecha el costo? Con la misma configuración, ResNet18 clasifica mejor en B (99.67% vs 96.17%) y C (99.98% vs 98.83%), pero tampoco habilita automatizar B ni C; en A obtiene 0.0% ACT frente a 90.3% de la clásica. Solo su embedding cuesta más en CPU que el pipeline clásico completo y añade ~45 MB de pesos más PyTorch. Producción = clásico; ResNet18 queda como referencia.

12. Model card

Uso previsto

Identificar el objeto (SKU) de una imagen de estación, estimar su ángulo de rotación en el plano [0, 360) con un score de incertidumbre en grados, y devolver las vistas de referencia más parecidas como evidencia. La salida incluye una decisión ACT / REVIEW / REJECT: el robot solo recibe un comando `PICK` con ángulo cuando la decisión es ACT; en cualquier otro caso recibe `HOLD` y el caso va a cola humana. ACT no garantiza acierto: el riesgo residual observado se reporta abajo.

Modelo desplegado

• Configuración `classic-logreg-v1` (`src/vision/recipe.py`): preprocesado (mediana 3×3 + máscara (Gauss 5×5, gris>40, apertura 3×3) + fondo a 0) → HSV(16x4x4)+HOG(64px,9or,8x8)+LBP(u8,2x2)+Hu → StandardScaler → PCA(150) → `logreg` {"C": 1.0}.

• Aumentación: 1 copia por vista de train: ruido σ~U(0,6), brillo ×U(0.8,1.2), blur σ~U(0.5,1) con p=0.3; validación = vistas limpias + 1 copia perturbada con la misma distribución.

• Ángulo: recuperación condicionada al objeto; k de interpolación elegido en validación (artefacto: k = 3).

• Score de incertidumbre angular: separación angular equivalente a la distancia al vecino más cercano según la curva distancia-vs-ángulo del objeto. Es un score heurístico en grados, no una cota del error; su umbral se elige para que el riesgo observado en validación P(clase incorrecta o |error| > 10° | ACT) sea ≤ 2 %.

• Umbrales: confianza ≥ 0.99, score ≤ 30.0°, distancia de desconocido ≤ 19.84. Validación de producción (90 conocidos paso 10° + 10 pseudo-desconocidos, vistas limpias + perturbadas): 5693 ACT, error 1.81% (IC95 [1.49, 2.19]%); pseudo-desconocidos que llegan a ACT 4.10% (criterio ≤ 5 %). Esta validación comparte imágenes con tests de los protocolos, así que no es una estimación independiente.

• Clases con ambigüedad rotacional (→ REVIEW): obj35, obj47, obj67, obj84, obj94, obj95, obj98.

• Artefacto: 17.59 MB, SHA-256 `4fce6c32cb4abe36`…, snapshot de código `5877577c981c4e46`… (incluido como code_snapshot.tar.gz), commit `4d6b14902c` (árbol sucio: True); latencia p50 ≈ 18.0 ms/imagen en CPU.

Datos

• COIL-100: 100 objetos × 72 vistas (paso 5°), 128×128 RGB, fondo oscuro y luz controlada. Hash de datos `e9e73124fbf0e964`…. Semilla 42.

• El artefacto usa las 7.200 vistas (+1 copia aumentada por vista) y no tiene test propio.

Métricas independientes (selección anidada por protocolo, test evaluado una vez)

Familia, hiperparámetros, k y umbrales se eligen solo con la validación interna del train de cada protocolo.

Métricas de la configuración desplegada (con salvedad)

Familia/C de la configuración desplegada se fijaron con validaciones agregadas de A–D que, en conjunto, se solapan con tests de otros protocolos: estas cifras no son independientes.

Desconocidos (selección anidada) — D estricto: rechazados 71.2%, llegan a ACT 12.64% (IC95 [10.41, 15.27]%). D variante: AUROC combinado 0.975, conocidos rechazados 1.79%.

Robustez a perturbaciones (configuración desplegada, test de A)

Aumentación cubre ruido σ≤6 y brillo ×0.8–1.2; σ=8 y ×0.7/×1.3 son extrapolación. Desconocidos bajo perturbación: ver reporte (D estricto).

Éxito e2e = clase correcta y error angular circular ≤ 10°. *Error entre ACT* = fracción de acciones del robot que serían empaque equivocado, desconocido aceptado o agarre fallido. N/A = política efectiva sin acciones.

Limitaciones conocidas

• Dataset de laboratorio: fondo oscuro uniforme, iluminación fija, cámara fija, un eje de rotación, sin oclusión, sin desenfoque por movimiento ni cambios de escala. El desempeño en planta no está demostrado.

• Perturbaciones fuera del rango de aumentación (ruido fuerte, cambios de brillo > ±20 %) degradan ángulo y cobertura y elevan el riesgo observado.

• Objetos rotacionalmente simétricos o con vistas opuestas parecidas: ángulo ambiguo → REVIEW.

• Arco ciego (B) y 12 vistas por SKU (C): política efectiva sin ACT.

• Desconocidos casi duplicados de un conocido (obj61 ≈ obj92) y algunos parecidos a varios conocidos (obj69) llegan a ACT; el criterio de falsa aceptación medido en validación (pseudo-desconocidos) no se trasladó por completo al test.

• El score de incertidumbre no es una probabilidad ni una cota.

Cuándo NO usarlo

• Con cámaras, fondos o iluminación distintos sin re-captura de referencias y recalibración de umbrales.

• Para rotaciones fuera del plano, objetos parcialmente ocultos o varios objetos en el cuadro.

• Como única barrera de seguridad: el robot debe mantener sus propias verificaciones (peso, código de barras, sensores de agarre).

• Para SKUs nuevos sin staging (≥ 12 vistas cubriendo ≥ 300°, métricas leave-one-out) y promoción explícita.

Recomendaciones para planta

Piloto en sombra (100 % revisión humana) para recalibrar umbrales con imágenes reales; ampliar la aumentación al rango de iluminación medido; monitorear ACT/REVIEW/REJECT, la distancia de novedad y las razones de REVIEW; versionar cada re-entrenamiento (hash de datos, SHA del artefacto, snapshot de código, MLflow) sin sobrescribir versiones publicadas.